



UNIVERSIDADE FEDERAL DO SUL DA BAHIA
INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DA BAHIA
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIAS E TECNOLOGIAS
AMBIENTAIS

YGOR AUGUSTO DOS SANTOS OLIVEIRA

DESENVOLVIMENTO DE UM MODELO DE REGRESSÃO
MÚLTIPLA POLINOMIAL DE ORDEM N PARA ANÁLISE DE
VARIÁVEIS AMBIENTAIS NA BAHIA

PORTO SEGURO

2026

YGOR AUGUSTO DOS SANTOS OLIVEIRA

DESENVOLVIMENTO DE UM MODELO DE REGRESSÃO
MÚLTIPLA POLINOMIAL DE ORDEM N PARA ANÁLISE DE
VARIÁVEIS AMBIENTAIS NA BAHIA

Projeto de dissertação submetido ao Programa de Pós-graduação em Ciências e Tecnologias Ambientais da Universidade Federal do Sul da Bahia e do Instituto Federal de Educação, Ciência e Tecnologia da Bahia, como parte dos requisitos necessários à qualificação.

Orientador: Prof. Dr. Fabrício Berton Zanchi

Coorientadora: Profa. Dra. Nyanne Silva Benfica

PORTO SEGURO

2026

OLIVEIRA, Ygor Augusto dos Santos. **Desenvolvimento de um modelo de regressão múltipla polinomial de ordem N para análise de variáveis ambientais na Bahia**. Orientador: Fabrício Berton Zanchi. Coorientadora: Nayanne Silva Benfica. 2026. Dissertação (Mestrado em Ciências e Tecnologias Ambientais) – Universidade Federal do Sul da Bahia; Instituto Federal de Educação, Ciência e Tecnologia da Bahia, Porto Seguro, 2026.

RESUMO

Modelos lineares convencionais podem ser insuficientes para representar relações ecológicas não lineares e interações entre variáveis ambientais. Este estudo desenvolveu e validou um Modelo de Regressão Múltipla Polinomial de ordem N (MRMP-N), estimado por Regressão Ridge, para analisar a Fotossíntese Líquida (PSN) nos biomas Mata Atlântica, Cerrado e Caatinga da Bahia, entre janeiro de 2001 e setembro de 2025. Foram utilizados dados mensais de sensoriamento remoto e variáveis climáticas, totalizando 297 observações por bioma. O grau polinomial e o conjunto de variáveis preditoras foram determinados empiricamente, e o desempenho foi avaliado por validação cruzada repetida, validação temporal e teste de Y-randomization. O modelo de grau 2 explicou 96,7% ($\pm 0,6$) da variância da PSN no Cerrado, 94,2% ($\pm 1,5$) na Caatinga e 73,7% ($\pm 5,9$) na Mata Atlântica. Em escala mensal e com agregação espacial por bioma, o RMSE de teste variou de 6,69 a 7,97 $\text{gC}\cdot\text{m}^{-2}\cdot\text{mês}^{-1}$ e o MAE de 5,08 a 6,29 $\text{gC}\cdot\text{m}^{-2}\cdot\text{mês}^{-1}$, com a multicolinearidade (VIF) atenuada pela regularização Ridge. Os resultados evidenciaram regimes ecológicos distintos de controle da produtividade primária: limitação hídrica sazonal no Cerrado, resposta pulsada à precipitação na Caatinga e controle multifatorial na Mata Atlântica. A análise do El Niño–Oscilação Sul (ENSO) indicou influência predominantemente indireta sobre a produtividade, com efeito direto sobre a PSN detectado apenas na Caatinga. Os resultados demonstram a viabilidade da regressão polinomial regularizada para representar relações ambientais complexas e reforçam a importância de abordagens diferenciadas para o monitoramento dos biomas baianos.

Palavras-chave: Modelagem ambiental; Regressão Ridge Polinomial; PSN; Bahia; Sensoriamento remoto.

OLIVEIRA, Ygor Augusto dos Santos. **Development of a polynomial multiple regression model of order N for the analysis of environmental variables in the state of Bahia.** Advisor: Fabrício Berton Zanchi. Co-advisor: Nayanne Silva Benfica. 2026. Master's Thesis (Master in Environmental Sciences and Technologies) – Universidade Federal do Sul da Bahia; Instituto Federal de Educação, Ciência e Tecnologia da Bahia, Porto Seguro, 2026

ABSTRACT

Conventional linear models may be insufficient to represent non-linear ecological relationships and interactions among environmental variables. This study developed and validated a Multiple Polynomial Regression Model of order N (MRMP-N), estimated by Ridge Regression, to analyze *Net Photosynthesis* (PSN) in the Atlantic Forest, Cerrado and Caatinga biomes of Bahia, Brazil, between January 2001 and September 2025. Monthly remote sensing data and climate variables were used, totaling 297 observations per biome. The polynomial degree and the set of predictor variables were determined empirically, and performance was assessed by repeated cross-validation, temporal validation and a Y-randomization test. The degree-2 model explained 96.7% (± 0.6) of PSN variance in the Cerrado, 94.2% (± 1.5) in the Caatinga and 73.7% (± 5.9) in the Atlantic Forest. At a monthly scale and with spatial aggregation by biome, test RMSE ranged from 6.69 to 7.97 $\text{gC}\cdot\text{m}^{-2}\cdot\text{month}^{-1}$ and MAE from 5.08 to 6.29 $\text{gC}\cdot\text{m}^{-2}\cdot\text{month}^{-1}$, with multicollinearity (VIF) mitigated by Ridge regularization. The results revealed distinct ecological regimes of primary productivity control: seasonal water limitation in the Cerrado, pulsed response to rainfall in the Caatinga and multifactorial control in the Atlantic Forest. The analysis of the *El Niño–Southern Oscillation* (ENSO) indicated a predominantly indirect influence on productivity, with a direct effect on PSN detected only in the Caatinga. The results demonstrate the feasibility of regularized polynomial regression to represent complex environmental relationships and reinforce the importance of differentiated approaches for monitoring the biomes of Bahia.

Keywords: Environmental modeling; Polynomial Ridge Regression; PSN; Bahia; Remote sensing.

LISTA DE SIGLAS

BURN – Área queimada (*Burned Area*), derivada do produto MODIS MCD64A1

ACF – Função de Autocorrelação (Autocorrelation Function)

CHIRPS – *Climate Hazards Group InfraRed Precipitation with Station data*

ETP – Evapotranspiração Potencial

ETR – Evapotranspiração Real

ENSO – El Niño-Oscilação Sul (*El Niño–Southern Oscillation*)

CPC – Centro de Previsão Climática da NOAA (*Climate Prediction Center*)

EV – Evapotranspiração

GPP – Produtividade Primária Bruta (*Gross Primary Production*)

INPE – Instituto Nacional de Pesquisas Espaciais

IPCC – Painel Intergovernamental sobre Mudanças Climáticas (*Intergovernmental Panel on Climate Change*)

MAE – Erro Absoluto Médio (*Mean Absolute Error*)

MCD64A1 – Produto MODIS de mapeamento de área queimada

MODIS – Espectrorradiômetro de Imagem de Resolução Moderada (*Moderate Resolution Imaging Spectroradiometer*)

NASA – Administração Nacional de Aeronáutica e Espaço dos Estados Unidos (*National Aeronautics and Space Administration*)

MOD11A2 – Produto MODIS de temperatura da superfície terrestre

MOD16 – Produto MODIS de evapotranspiração

MOD17 – Produto MODIS de Fotossíntese Líquida

MQO – Mínimos Quadrados Ordinários

MRMP-N – Modelo de Regressão Múltipla Polinomial de ordem N

NPP – Produtividade Primária Líquida (*Net Primary Production*)

NOAA – Administração Nacional Oceânica e Atmosférica dos Estados Unidos (*National Oceanic and Atmospheric Administration*)

ONI – Índice Oceânico Niño (*Oceanic Niño Index*)

PSN – Fotossíntese Líquida (*Net Photosynthesis*)

QSAR – Relação Quantitativa Estrutura-Atividade (*Quantitative Structure-Activity Relationship*)

PRE – Precipitação

R^2 – Coeficiente de Determinação

RMSE – Raiz do Erro Quadrático Médio (*Root Mean Square Error*)

TST – Temperatura da Superfície Terrestre

VIF – Fator de Inflação da Variância (*Variance Inflation Factor*)

WAI – Índice de Disponibilidade Hídrica (*Water Availability Index*)

LISTA DE FIGURAS

Nº	Título	Página
Figura 1	Fluxos de carbono estimados pelo algoritmo MODIS/MOD17: relação entre GPP, PSN e NPP	12
Figura 2	Mapa de localização e distribuição dos biomas na área de estudo	20
Figura 3	Fluxo metodológico do modelo MRMP-N	21
Figura 4	Esquemas de particionamento treino/teste (RepeatedKFold, GroupKFold por ano e TimeSeriesSplit)	30
Figura 5	Regressão linear simples entre a PSN e cada variável ambiental nos três biomas	33
Figura 6	Observado vs. predito do MRMP-N nos três biomas	34
Figura 7	Seleção do grau polinomial do MRMP-N nos três biomas	37
Figura 8	Importância relativa das variáveis preditoras no modelo MRMP-N nos três biomas	38
Figura 9	Diagnóstico de resíduos do MRMP-N nos três biomas	43
Figura 10	Y-randomization do MRMP-N nos três biomas	44
Figura 11	Distribuição das variáveis ambientais por fase ENSO na Mata Atlântica	46
Figura 12	Distribuição das variáveis ambientais por fase ENSO no Cerrado	46
Figura 13	Distribuição das variáveis ambientais por fase ENSO na Caatinga	47

LISTA DE TABELAS

Nº	Título	Página
Tabela 1	Variáveis para predição da Fotossíntese Líquida (PSN)	22

Tabela 2	Desempenho preditivo do MRMP-N nos biomas Mata Atlântica, Cerrado e Caatinga na Bahia	34
Tabela 3	Comparação do desempenho preditivo (R^2) dos modelos sob diferentes estratégias de validação	35
Tabela 4	Tipologia ecológica dos regimes de produtividade primária na Bahia	41
Tabela 5	Fator de Inflação da Variância (VIF) das variáveis preditoras por bioma	45
Tabela A1	Base de dados mensal dos três biomas (2001–2025)	53
Tabela A2	Desempenho das 10 combinações de variáveis ambientais por bioma	63
Tabela A3	Efeito da remoção das componentes de sazonalidade harmônica no desempenho do MRMP-N	65
Tabela A4	Proporção da variância das variáveis climáticas explicada pelo ciclo anual	65

SUMÁRIO

1	APRESENTAÇÃO E JUSTIFICATIVA.....	9
2	FUNDAMENTAÇÃO TEÓRICA.....	10
3	QUESTÃO CENTRAL E HIPÓTESES.....	17
3.1	Questão central.....	17
3.2	Hipóteses.....	17
4	OBJETIVOS.....	17
4.1	Objetivo geral.....	17
4.2	Objetivos específicos.....	18
5	MATERIAL E MÉTODOS.....	18
5.1	Área de Estudo.....	18
5.2	Dados e Pré-processamento.....	21
5.3	Especificação do Modelo (MRMP-N).....	25
5.4	Análise estatística.....	27
5.5	Validação do Modelo.....	28

5.6	Ferramentas Computacionais e Reprodutibilidade.....	31
6	RESULTADOS E DISCUSSÃO.....	32
6.1	Desempenho preditivo do modelo por bioma.....	32
6.2	Seleção do grau polinomial e variáveis preditoras.....	36
6.3	Papel da disponibilidade hídrica no Cerrado e os regimes de produtividade primária dos biomas da Bahia.....	39
6.4	Diagnóstico estatístico do modelo.....	42
6.5	Influência do ENSO sobre a produtividade dos biomas.....	45
6.6	Implicações ambientais e para o planejamento regional.....	48
7	CONSIDERAÇÕES FINAIS.....	49
8	REFERÊNCIAS.....	66

1 APRESENTAÇÃO E JUSTIFICATIVA

A Fotossíntese Líquida (PSN) constitui um importante indicador da atividade fotossintética dos ecossistemas terrestres, representando o carbono assimilado pela vegetação após o desconto da respiração de manutenção de folhas e raízes finas. Por refletir diretamente a resposta fisiológica da cobertura vegetal às condições ambientais, a PSN é amplamente utilizada para monitorar a dinâmica dos ecossistemas e avaliar alterações decorrentes de fatores climáticos e antrópicos. No contexto das mudanças climáticas globais, sua relevância é amplificada, pois a Fotossíntese Líquida atua tanto como um componente chave no ciclo global do carbono quanto como um indicador sensível às alterações de temperatura, precipitação e radiação solar. Portanto, a modelagem precisa dos fatores que influenciam a Fotossíntese Líquida é imperativa para a ciência ambiental e para a formulação de políticas públicas eficazes.

O estado da Bahia apresenta um sistema ambiental de notável complexidade, onde fatores climáticos, geográficos e antrópicos interagem de maneira sinérgica e não linear. O estado reúne três importantes biomas brasileiros, a saber, Mata Atlântica, Cerrado e Caatinga, caracterizados por diferentes regimes climáticos, formações vegetacionais e níveis de pressão antrópica, que variam da intensa fragmentação e urbanização na Mata Atlântica, passando pela expansão da fronteira agrícola no Cerrado, até os processos de degradação e desertificação na Caatinga. Essa heterogeneidade ambiental produz padrões distintos de resposta da vegetação, dificultando a representação dos processos ecológicos por modelos lineares convencionais. Abordagens de modelagem tradicionais, baseadas em regressão linear simples, podem ser inadequadas para capturar tais dinâmicas, resultando frequentemente em representações distorcidas que subestimam a complexidade das interações. A incapacidade de modelar as relações não lineares e os efeitos de interação entre preditores leva a uma compreensão incompleta dos processos ecológicos e, conseqüentemente, a decisões de gestão ambiental menos eficazes do que poderiam ser.

Para superar essas limitações metodológicas, este estudo emprega um Modelo de Regressão Múltipla Polinomial de ordem N (MRMP-N). Esta abordagem foi selecionada por sua capacidade de representar relações não lineares e efeitos de interação entre variáveis ambientais, permitindo capturar padrões ecológicos que dificilmente seriam descritos por modelos lineares convencionais. Modelos de regressão polinomial com seleção sistemática de termos têm sido aplicados tanto na predição quantitativa estrutura-atividade em química medicinal (Guimarães et al., 2024) quanto, em sentido mais amplo, na modelagem de respostas ecológicas não lineares, para as quais abordagens flexíveis superam consistentemente as

estritamente lineares (Hao et al., 2019). O MRMP-N permite uma representação mais fiel da complexa realidade ambiental, na qual a resposta da Fotossíntese Líquida a um determinado fator pode depender do nível de outro. A especificação do modelo seguiu um protocolo sistemático e reproduzível, que inclui a padronização do conjunto de dados, a adição gradual de termos polinomiais e de interação, a seleção e validação dos modelos com base em critérios estatísticos e métricas de desempenho preditivo, e a avaliação rigorosa do desempenho do modelo final por meio de métricas consagradas, como o coeficiente de determinação (R^2), a raiz do erro quadrático médio (RMSE) e a análise de resíduos.

A escolha do modelo de regressão múltipla polinomial (MRMP-N) é estratégica, pois permite avaliar a contribuição relativa das variáveis preditoras para o desempenho do modelo, como precipitação, temperatura, evapotranspiração e disponibilidade hídrica, sobre a Fotossíntese Líquida (PSN). O estudo desenvolveu e validou um modelo preditivo capaz de estimar a PSN a partir de variáveis climáticas e ambientais. Buscou-se identificar os fatores de maior influência sobre a dinâmica da PSN nos ecossistemas baianos, bem como quantificar sua contribuição relativa por meio de métricas estatísticas e análises de sensibilidade, com validação por *RepeatedKfold*, esquemas complementares de validação temporal (*GroupKfold* por ano e *TimeSeriesSplit* com janela expansível) e teste de Y-randomization. Os resultados poderão subsidiar ações de monitoramento ambiental, avaliação dos impactos das mudanças climáticas e planejamento da gestão dos recursos naturais na Bahia, contribuindo para uma melhor compreensão dos fatores que controlam a dinâmica da PSN nos diferentes biomas do estado. Por sua abordagem quantitativa na análise de processos ecológicos, este projeto está alinhado à Área de Concentração em Ciências e Tecnologias Ambientais e se vincula à Linha de Pesquisa em Tecnologias Ambientais do PPGCTA.

2 FUNDAMENTAÇÃO TEÓRICA


A compreensão do funcionamento ambiental requer abordagens capazes de lidar com sistemas complexos, nos quais múltiplos fatores atuam de forma conjunta e frequentemente não linear. As avaliações mais recentes do Painel Intergovernamental sobre Mudanças Climáticas (IPCC, 2022) ressaltam que as respostas dos ecossistemas a essas pressões podem apresentar limiares e efeitos combinados, variando entre regiões e escalas. Essa perspectiva foi consolidada pela ecologia teórica desde o trabalho seminal de Levin (1998), que descreve os ecossistemas como sistemas adaptativos complexos, nos quais padrões de larga escala emergem de interações locais. Evidências recentes reforçam essa visão: Flores et al. (2024), ao analisarem

transições críticas no sistema florestal amazônico, demonstram que ecossistemas tropicais podem cruzar limiares a partir dos quais a resposta deixa de ser proporcional à forçante (o fator externo que a provoca, como o aumento da temperatura ou a redução da chuva), evidenciando a necessidade de modelos que acomodem dependência de contexto e comportamento não linear, dinâmica igualmente relevante para os biomas analisados neste estudo Mata Atlântica, Cerrado e Caatinga.

Nesse cenário, a fotossíntese líquida (PSN, *net photosynthesis*) constitui uma variável-síntese particularmente informativa do funcionamento ecológico terrestre. A fonte dessa variável é o sensor MODIS (*Moderate Resolution Imaging Spectroradiometer*), instrumento orbital da agência espacial norte-americana NASA a bordo dos satélites *Terra* (lançado em 1999) e *Aqua* (2002). O MODIS observa toda a superfície terrestre a cada um ou dois dias, em 36 bandas espectrais e resoluções de 250 m a 1 km; a partir dessas imagens, a NASA gera produtos derivados identificados por códigos, como o MOD17 (produtividade da vegetação), o MOD16 (evapotranspiração), o MOD11 (temperatura da superfície) e o MCD64 (área queimada), todos distribuídos gratuitamente. O algoritmo MOD17 (Running et al., 2004; Running; Zhao, 2021) estima três níveis de fluxo de carbono, cuja relação está esquematizada na Figura 1. A Produtividade Primária Bruta (GPP) corresponde a todo o carbono retirado da atmosfera pela fotossíntese. Parte desse carbono é consumida imediatamente pela respiração de manutenção das folhas e das raízes finas, isto é, o custo de manter vivos os tecidos de vida curta; o que sobra é a Fotossíntese Líquida (PSN), o carbono que a vegetação efetivamente acumula em escala de dias a semanas. Se, além disso, forem descontadas a respiração de manutenção dos demais tecidos vivos (lenho e raízes grossas) e a respiração de crescimento, o custo de construir biomassa nova, chega-se à Produtividade Primária Líquida (NPP), calculada por agregação anual (Zhao et al., 2005; Running; Zhao, 2021). Em termos de equações, $PSN = GPP - R_m(\text{folhas}) - R_m(\text{raízes finas})$ e $NPP = PSN - R_m(\text{lenho e raízes grossas}) - R_g$, em que R_m é a respiração de manutenção e R_g a respiração de crescimento. A PSN é, portanto, um saldo intermediário entre a GPP e a NPP.

Figura 1 - Fluxos de carbono estimados pelo algoritmo MODIS/MOD17: relação entre GPP, PSN e NPP.

Fluxos de carbono estimados pelo algoritmo MODIS/MOD17



Atmosfera (CO₂) → fotossíntese → GPP → PSN → NPP: cada etapa desconta uma parcela de respiração.

Variável-resposta deste estudo: PSN mensal, por bioma (compostos de 8 dias do MOD17A2H agregados ao mês).

A PSN representa o saldo líquido de carbono assimilado em escala subanual, sendo um indicador direto da atividade fotossintética da vegetação e um *proxy* robusto da resposta do ecossistema às condições ambientais. A adoção da PSN como variável-resposta deste estudo justifica-se por sua resolução temporal compatível com a escala mensal de análise e por capturar a dinâmica fisiológica da vegetação sem a defasagem inerente à integração anual da NPP. As características do produto que a fornece (resolução espacial e temporal, agregação mensal e por bioma) estão descritas na seção Dados e Pré-processamento.

A dependência da produtividade vegetal em relação ao clima é um princípio consolidado. Nemani et al. (2003) demonstraram, em escala global, que a produtividade terrestre é amplamente controlada por temperatura, disponibilidade de água e radiação, com a limitação dominante variando geograficamente.

Em ecossistemas tropicais sazonais, o balanço hídrico assume papel central. Vourlitis et al. (2022), em estudos de fluxo por *eddy covariance* no Cerrado brasileiro, estimaram GPP entre 16,3 e 18,4 MgC ha⁻¹ ano⁻¹, evidenciando o forte controle exercido pela alternância entre estação seca e chuvosa sobre a evapotranspiração e a assimilação de carbono. O Cerrado, com precipitação anual entre 800 e 1.800 mm e marcada sazonalidade, exemplifica um regime em que a oferta hídrica exerce forte controle sobre o ritmo da atividade fotossintética. Essa dependência fisiológica direta da produtividade em relação às condições ambientais é o fundamento que permite usar variáveis climáticas para estimar a PSN. Nos dados deste estudo esse controle é direto: no Cerrado baiano, a evapotranspiração explica sozinha 74,8% da variância mensal da PSN e o índice de disponibilidade hídrica (WAI) 74,1% (regressões lineares simples, $n = 297$, $p < 0,001$), contra 59,2% da temperatura e 7,7% da precipitação do mesmo

mês (Figura 5, no Capítulo de Resultados). Na Mata Atlântica, por contraste, a evapotranspiração explica apenas 12,5% da variância da PSN.

Contudo, essa relação raramente é linear. A literatura ecológica documenta que a produtividade aumenta com a precipitação apenas até determinado ponto, a partir do qual os retornos decrescem ou saturam, configurando respostas em platô ou em “U”. Hao et al. (2019), em revisão sobre modelagem ecológica, mostram que modelos capazes de representar formas de resposta não lineares superam consistentemente abordagens estritamente lineares. Estudos empíricos quantificam esses limiares: em florestas tropicais sazonais, Linger et al. (2020) identificaram efeito de limiar da precipitação sobre a produtividade, com a NPP respondendo mais intensamente abaixo de cerca de 229 mm mensais; em florestas subtropicais, Mwangi et al. (2025) observaram redução não linear da GPP abaixo de um limiar de aproximadamente 1.200 mm anuais; e experimentos de exclusão de chuva em savanas confirmam reduções significativas da NPP de árvores, arbustos e serapilheira sob déficit hídrico (Jin et al., 2018). A existência desses pontos de inflexão é precisamente o que motiva, do ponto de vista teórico, o emprego de uma estrutura polinomial, capaz de representar curvas de resposta e saturação sem impor uma forma funcional rígida.

Além do controle climático, os ecossistemas estão submetidos a pressões antrópicas que atuam por mecanismos distintos e que devem ser claramente diferenciadas das forçantes climáticas. Enquanto o clima modula a produtividade por vias fisiológicas, como disponibilidade hídrica, temperatura e radiação, as pressões humanas alteram diretamente a estrutura e a cobertura da vegetação, introduzindo variabilidade que não é capturável apenas por preditores climáticos. Essas pressões, que incluem desmatamento, expansão agropecuária, silvicultura, fragmentação da paisagem e degradação do solo, elas apresentam magnitudes expressivas e bem documentadas. No Cerrado, segundo a Coleção 10 do MapBiomias (2025), foram desmatados cerca de 40,5 milhões de hectares de vegetação nativa entre 1985 e 2024, uma redução de aproximadamente 28% da cobertura; nesse período, a área ocupada pela agropecuária cresceu 74% (cerca de 39,9 milhões de hectares), de modo que, em 2024, aproximadamente 47,9% do bioma correspondia a áreas de uso antrópico. O Cerrado consolidou-se, nos anos recentes, como um dos biomas que mais perderam vegetação nativa no país, com a fronteira agrícola MATOPIBA, que inclui o oeste da Bahia, concentrando a maior parte dessa conversão.

Na Mata Atlântica, a perda recente foi de cerca de 4,4 milhões de hectares (-11%) entre 1985 e 2024 (MapBiomias, 2025), mas o quadro mais crítico é estrutural: restam apenas cerca de

12 a 16% da cobertura florestal original, com mais de 80% dos fragmentos remanescentes menores que 50 ha e elevada distância média entre eles, o que intensifica os efeitos de borda e compromete a conectividade (Ribeiro et al., 2009). Na Bahia, esse quadro soma-se à expansão da silvicultura de eucalipto e ao mosaico histórico com a cacauicultura-cabruca, fatores que reconfiguram a paisagem e a produtividade regional.

Na Caatinga, a Coleção 10 do MapBiomias (2025) registra perda de cerca de 9,2 milhões de hectares de vegetação nativa entre 1985 e 2024 (-15%), enquanto cerca de 37% do bioma (aproximadamente 32,3 milhões de hectares) passou a corresponder a uso agropecuário em 2024, tendo a pastagem se expandido 106% e a agricultura 1636% desde 1985; paralelamente, cerca de 100.000 km² do semiárido encontram-se em processo de desertificação. Esse contraste entre biomas foi documentado regionalmente por Benfica et al. (2022), que demonstraram, na Bahia, que a produtividade responde não apenas a variações de precipitação e temperatura, mas também a mudanças no uso e cobertura da terra e à ocorrência de queimadas, com diferenças nítidas entre Mata Atlântica, Cerrado e Caatinga.

Esses vetores de pressão não apenas alteram a paisagem, mas reduzem de forma mensurável a capacidade fotossintética da vegetação, atuando sobre a PSN por mecanismos específicos. Na Mata Atlântica, a fragmentação opera principalmente pelo efeito de borda: a exposição das margens dos fragmentos altera o microclima, eleva a mortalidade de árvores e favorece a substituição de espécies de dossel por pioneiras de menor densidade de carbono, reduzindo progressivamente a biomassa fotossinteticamente ativa. A partir de 1.819 inventários florestais, Lima et al. (2020) estimaram que os fragmentos do bioma apresentam, em média, de 25% a 32% menos biomassa do que áreas de baixa perturbação, perda equivalente à destruição de 55 a 70 mil km² de floresta; Broggio et al. (2024) demonstraram que essa degradação de borda constitui um fluxo contínuo de perda de carbono ao longo de 35 anos no bioma. No Cerrado e na sua fronteira agrícola no oeste da Bahia, a conversão da vegetação nativa em pastagem e lavoura reduz a evapotranspiração e a fixação de carbono, alterando os estoques e os fluxos do ecossistema (Dionizio et al., 2020). A redução ocorre porque as gramíneas das pastagens têm sistema radicular raso e perdem grande parte da área foliar na estação seca, enquanto a vegetação nativa, com raízes profundas, continua acessando a água do subsolo e transpirando ao longo do ano; assim, embora o pasto possa ter índice de área foliar comparável no auge da estação chuvosa, sua evapotranspiração anual é menor, sobretudo nos meses secos. Por fim, as queimadas removem a cobertura vegetal e, somadas ao corte raso e ao sobrepastejo, podem empurrar ecossistemas semiáridos como a Caatinga para além de seus limiares de

resiliência, comprometendo a recuperação da produtividade (Benfica et al., 2022; Silva et al., 2026). Em conjunto, esses mecanismos explicam por que a variabilidade da PSN nas áreas sob forte pressão antrópica não é integralmente capturada por preditores climáticos.

A relevância dessa distinção é evidenciada por trabalhos que decompõem os controladores da produtividade. Silva et al. (2026), analisando os fatores determinantes da produtividade na Caatinga por meio do modelo CASA, identificaram que a precipitação domina a resposta em 56,4% do bioma, o estresse térmico em 26,1% e a mudança de uso e cobertura da terra em 17,4%, quantificando, portanto, o peso relativo entre forçantes climáticas e pressão antrópica.

Esse mesmo estudo evidencia a sensibilidade da produtividade a eventos climáticos de larga escala: anos de El Niño contribuem para reduções da produtividade, enquanto anos de La Niña associam-se a maior produtividade, refletindo a resposta do bioma aos pulsos induzidos pelo El Niño-Oscilação Sul (ENSO). Esse padrão é coerente com a compreensão de que o ENSO não atua de forma direta sobre a vegetação, mas modula variáveis intermediárias, sobretudo temperatura e precipitação, que, por sua vez, condicionam a produtividade, configurando um padrão compatível com um mecanismo de influência indireta (do Índice Oceânico Niño, ONI, medida oficial da NOAA para o ENSO que corresponde à anomalia média de três meses da temperatura da superfície do mar no Pacífico equatorial central, para a temperatura e a precipitação regionais, e destas para a PSN).

Do ponto de vista dos dados, o sensoriamento remoto fornece a base empírica para tais análises. Os produtos MODIS/MOD17, centrais para este estudo, são disponibilizados já processados e submetidos a controle de qualidade pelo próprio algoritmo, que inclui camadas de *Quality Control* e versões com preenchimento de falhas (Running; Zhao, 2021). Essa característica reduz a necessidade de etapas adicionais de pré-processamento e controle de qualidade, constituindo uma vantagem operacional relevante frente a produtos de outros sensores que exigem etapas extensas de correção, e permite que o esforço analítico se concentre na modelagem estatística das relações ecológicas, conforme já explorado em escala regional por Benfica et al. (2022).

Nesse enquadramento, a regressão múltipla com termos polinomiais surge como alternativa metodológica coerente para representar as relações não lineares descritas. A estrutura adotada neste trabalho inspira-se na abordagem de modelagem polinomial sistemática desenvolvida por Guimarães et al. (2024), originalmente aplicada à predição quantitativa estrutura-atividade (QSAR), isto é, a modelos que preveem a atividade biológica de uma

molécula (no caso, o índice de inibição da atividade celular de compostos antimaláricos) a partir de características estruturais de moléculas sabidamente inibidoras e não inibidoras, cuja contribuição metodológica relevante reside na construção incremental do modelo e na ênfase em reprodutibilidade e rastreabilidade. No presente estudo, essa lógica é transposta ao contexto ambiental e adaptada por meio de duas decisões metodológicas fundamentadas.

A primeira é o uso da regressão Ridge no lugar dos mínimos quadrados ordinários. Quando se criam termos quadráticos e de interação a partir de variáveis que já são correlacionadas entre si (por exemplo, evapotranspiração e disponibilidade hídrica), o modelo passa a conter muitas variáveis que carregam quase a mesma informação. Na regressão clássica isso torna os coeficientes instáveis: pequenas mudanças nos dados produzem coeficientes muito diferentes. A regressão Ridge acrescenta uma penalidade (chamada L2) que impede os coeficientes de crescerem demais, trocando um pequeno viés por muito mais estabilidade, o que a torna adequada a preditores correlacionados.

A segunda é a determinação empírica do grau polinomial ótimo, em substituição à fixação prévia de um grau, garantindo que a complexidade do modelo seja calibrada pelos próprios dados. Assim, ao adotar a regressão polinomial regularizada, segue-se uma abordagem justificada simultaneamente pela complexidade teórica dos ecossistemas (Levin, 1998; Flores et al., 2024), pela evidência empírica de que respostas ecológicas são frequentemente não lineares e sujeitas a limiares (Hao et al., 2019), e pela necessidade de controle estatístico da multicolinearidade inerente à expansão polinomial.

Por fim, a escolha das escalas temporal e espacial constitui um eixo metodológico decisivo. A agregação temporal, neste caso mensal, deve equilibrar a estabilidade do sinal e o objetivo analítico, evitando o sobreajuste a flutuações transitórias e mantendo resolução suficiente para captar a dinâmica sazonal da PSN. Da mesma forma, a compatibilização espacial das camadas de dados, com sistema de referência e resolução coerentes, é um procedimento constitutivo que sustenta a qualidade inferencial do modelo. Esses cuidados permitem que a análise se concentre na estrutura ecológica das relações, traduzindo em linguagem estatística os padrões que a ecologia sugere: curvas de resposta, pontos de inflexão e efeitos combinados entre clima e pressões antrópicas sobre a fotossíntese líquida.

3 QUESTÃO CENTRAL E HIPÓTESES

A presente pesquisa é guiada por uma questão central que desdobra a relação entre as condições ambientais e a produtividade primária, medida pela Fotossíntese Líquida, dos biomas na Bahia.

3.1 Questão central

Em que medida um modelo de regressão polinomial, aplicado à Bahia, é capaz de explicar e quantificar a influência de preditores ambientais e climáticos sobre a variação da Fotossíntese Líquida (PSN)?

3.2 Hipóteses

H1: A expansão polinomial não linear apresentará melhor desempenho preditivo em relação ao modelo linear de grau 1, mantendo nível controlado de sobreajuste, com o grau ótimo definido, entre os graus 1 a 5, como aquele que maximiza o R^2 de teste mantendo a diferença entre o R^2 de treino e o de teste abaixo de 10 pontos percentuais.

H2: O conjunto de variáveis ambientais, associado aos componentes harmônicos de sazonalidade, explicará pelo menos 60% da variância mensal da PSN em cada bioma, com diferenças na composição do conjunto ótimo de preditores entre os biomas.

H3: O Índice Oceânico Niño (ONI) não atuará como preditor direto da PSN, mas exercerá influência indireta por meio da modulação de variáveis climáticas intermediárias, como temperatura e precipitação, sugerindo um mecanismo de influência indireta mediado por variáveis climáticas regionais.

4 OBJETIVOS

4.1 Objetivo geral

Desenvolver e validar um Modelo de Regressão Múltipla Polinomial de ordem N (MRMP-N), estimado por Regressão Ridge, para quantificar a influência de variáveis ambientais sobre a Fotossíntese Líquida (PSN) nos biomas Mata Atlântica, Cerrado e Caatinga da Bahia.

4.2 Objetivos específicos

Determinar empiricamente o grau polinomial e o conjunto de variáveis ambientais de melhor desempenho preditivo em cada bioma.

Avaliar a robustez e a capacidade de generalização do modelo, inclusive sob validação que respeita a ordem cronológica dos dados.

Comparar o desempenho preditivo e os controles ambientais da PSN entre os três biomas.

Investigar a influência do El Niño–Oscilação Sul (ENSO) sobre a PSN e sobre as variáveis climáticas intermediárias (EV, PRE e TST) nos três biomas.

5 MATERIAL E MÉTODOS

Este capítulo descreve, nesta ordem, a área de estudo, a base de dados e os procedimentos de pré-processamento adotados, e o modelo de regressão polinomial desenvolvido, detalhando sua especificação, a análise estatística, os procedimentos de validação e as ferramentas computacionais empregadas.

5.1 Área de Estudo

A área de estudo corresponde ao estado da Bahia, situado na região Nordeste do Brasil, com território de aproximadamente 564.733 km², o que o torna o quinto maior estado do país e a unidade da federação que faz divisa com o maior número de estados. Sua posição intertropical e a extensa faixa litorânea, de cerca de 1.188 km, condicionam uma elevada variabilidade climática e ambiental ao longo do território.

A Bahia apresenta elevada diversidade ambiental, abrigando porções expressivas de três biomas brasileiros: Caatinga, Cerrado e Mata Atlântica, que ocupam, respectivamente, cerca de 54%, 27% e 19% do território estadual (IBGE, 2004). Essa coexistência confere à região elevada heterogeneidade de regimes climáticos, formações vegetacionais e padrões de uso do solo, conforme ilustrado na Figura 2.

Do ponto de vista climático, segundo a classificação de Köppen para o Brasil (Alvares et al., 2013), o litoral e o leste do estado, onde predomina a Mata Atlântica, apresentam clima tropical úmido, com temperaturas médias elevadas e maiores índices de precipitação. O interior e o Norte, dominados pela Caatinga, caracterizam-se por clima semiárido, mais seco e quente,


com chuvas escassas e irregulares, podendo a precipitação anual variar de cerca de 240 a 1.500 mm, com ampla porção recebendo menos de 750 mm. O oeste e o sul do estado, sob domínio do Cerrado, apresentam clima tropical sazonal, com estação seca bem definida e papel hidrológico relevante, por abrigarem nascentes de importantes bacias, como a do Rio São Francisco.

Cada bioma impõe um regime ecológico distinto à dinâmica da vegetação: a Mata Atlântica, mais úmida, é também a mais fragmentada e pressionada pela expansão urbana, pela silvicultura de eucalipto e pela cacauicultura; o Cerrado é fortemente condicionado pela sazonalidade hídrica e pelo avanço da fronteira agrícola; e a Caatinga, semiárida, responde de forma pulsada às chuvas, isto é, com aumentos rápidos da produtividade logo após cada evento de precipitação seguidos de queda igualmente rápida na estiagem, e encontra-se sujeita a processos de degradação e desertificação. Essa diversidade de controles ambientais justifica a abordagem comparativa entre biomas adotada neste estudo.

Do ponto de vista hidrológico, o Cerrado baiano abriga nascentes que abastecem bacias hidrográficas regionais, entre elas afluentes do Rio São Francisco, sustentando atividades agropecuárias, comunidades rurais e ecossistemas a jusante. A Mata Atlântica do sul da Bahia integra o Corredor Central da Mata Atlântica, um dos eixos prioritários da conservação da biodiversidade no país, e concentra iniciativas de restauração florestal, ainda em fase inicial na maior parte dos casos, alinhadas ao Plano Nacional de Recuperação da Vegetação Nativa (PLANAVEG) e ao Zoneamento Ecológico-Econômico da Bahia.

O uso do solo difere entre os biomas: na Mata Atlântica predominam os mosaicos de fragmentos florestais intercalados por pastagens, cacauicultura, silvicultura de eucalipto e áreas urbanas; no oeste do estado, a fronteira agrícola do MATOPIBA converteu extensas áreas de Cerrado em lavouras de grãos e pastagens; e na Caatinga a pecuária extensiva, a agricultura de sequeiro e a extração de lenha respondem pela maior parte da conversão e da degradação da vegetação nativa (MapBiomas, 2025). O estado abriga ainda povos indígenas de diversas etnias (entre elas Pataxó, Pataxó Hã-Hã-Hãe, Tupinambá, Kiriri, Tuxá, Pankararé, Truká e Kaimbé), comunidades quilombolas e agricultores familiares que dependem diretamente dos serviços ecossistêmicos associados à produtividade da vegetação. Essa diversidade de controles ambientais e de pressões antrópicas justifica a abordagem comparativa entre biomas adotada neste estudo.


Figura 2 - Mapa de localização e distribuição dos biomas na área de estudo.



Fonte: IBGE — Biomas (2019) e limite estadual (2020). Datum SIRGAS 2000 (EPSG:4674). Contorno da América do Sul: Natural Earth.

O fluxo metodológico completo do MRMP-N, da organização da base de dados à validação final, é sintetizado na Figura 3; cada etapa é detalhada nas seções seguintes.

Figura 3 - Fluxo metodológico do modelo MRMP-N.



5.2 Dados e Pré-processamento

Os dados utilizados neste estudo foram organizados em formato tabular, com uma observação mensal por bioma, a partir de produtos de sensoriamento remoto e de uma base de precipitação, todos de acesso público e gratuito. A variável resposta, a Fotossíntese Líquida (PSN), provém do produto MOD17A2H, e a evapotranspiração real (EV) e a potencial (ETP) do produto MOD16A2, ambos do sensor MODIS a bordo do satélite *Terra*, da NASA; a temperatura da superfície terrestre (TST) provém do produto MOD11A2 e a área queimada (BURN) do MCD64A1, do mesmo sensor. A precipitação (PRE) provém do produto CHIRPS (*Climate Hazards Group InfraRed Precipitation with Station data*), que combina estimativas por satélite e estações pluviométricas, e o Índice Oceânico Niño (ONI) da tabela oficial do Centro de Previsão Climática (CPC) da NOAA. O produto MOD17A2H é distribuído em compostos de oito dias com resolução espacial de 500 metros e fornece a PSN como a diferença entre a Produtividade Primária Bruta (GPP) e a respiração de manutenção de folhas e raízes finas; os compostos foram agregados à escala mensal e os pixels de cada bioma dentro dos limites da Bahia foram agregados espacialmente, seguindo o procedimento de Benfica et al.

(2022), que organizou a base original de 2001 a 2020, aqui estendida até 2025. Os produtos MODIS podem ser obtidos pelo portal NASA Earthdata ou pelas plataformas AppEEARS e Google Earth Engine, o CHIRPS pelo servidor da Universidade da Califórnia em Santa Bárbara e o ONI pela página do CPC; a base mensal consolidada usada neste estudo está reproduzida integralmente no Apêndice A e o código-fonte está disponível em repositório público, permitindo a reprodução de todos os resultados. As variáveis dependentes e preditoras que compõem o modelo estão detalhadas na Tabela 1.

Tabela 1 - Variáveis para predição da Fotossíntese Líquida (PSN).

Variável	Descrição	Unidade	Fonte / acesso
PSN	Fotossíntese Líquida (variável resposta)	$\text{gC} \cdot \text{m}^{-2} \cdot \text{mês}^{-1}$	MOD17A2H (NASA Earthdata) / Benfica et al. (2022)
EV	Evapotranspiração mensal	$\text{mm} \cdot \text{mês}^{-1}$	MOD16A2 (NASA Earthdata) / Benfica et al. (2022)
PRE	Precipitação acumulada mensal	$\text{mm} \cdot \text{mês}^{-1}$	CHIRPS (UCSB) / Benfica et al. (2022)
TST	Temperatura da Superfície Terrestre	$^{\circ}\text{C}$	MOD11A2 (NASA Earthdata) / Benfica et al. (2022)
WAI	Índice de Disponibilidade Hídrica (razão ETR/ETP)	adimensional	ETR/ETP do MOD16A2 / Benfica et al. (2022)
BURN	Área queimada	ha	MCD64A1 (NASA Earthdata) / Benfica et al. (2022)
ONI	Índice Oceânico Niño	adimensional	NOAA/CPC (oni.ascii.txt)
SAZsin	Componente harmônica senoidal do ciclo anual	adimensional	Derivada do indexador MÊS
SAZcos	Componente harmônica cosseno do ciclo anual	adimensional	Derivada do indexador MÊS

A variável resposta é a Fotossíntese Líquida (PSN), e as variáveis preditoras candidatas são a evapotranspiração (EV), a precipitação acumulada (PRE), a temperatura da superfície terrestre (TST), o índice de disponibilidade hídrica (WAI), definido como a razão entre a

evapotranspiração real e a potencial (ETR/ETP) e que expressa o grau em que a demanda atmosférica por água é atendida pela água disponível no sistema, e a área queimada (BURN), acrescidas das duas componentes harmônicas de sazonalidade derivadas do indexador mensal. O conjunto abrange o período de janeiro de 2001 a setembro de 2025, em escala mensal ($n = 297$ meses por bioma); os três últimos meses de 2025 foram excluídos por ainda não haver dado de precipitação publicado. O ONI é publicado pela NOAA como média móvel de três meses (por exemplo, DJF, JFM) atribuída ao mês central do trimestre; cada mês da série recebeu, portanto, o valor do trimestre centrado nele (janeiro = DJF, fevereiro = JFM, e assim por diante), o que mantém a resolução mensal sem interpolação. O ONI não compõe o conjunto de preditores do modelo principal, sendo empregado especificamente na análise da influência do El Niño-Oscilação Sul (ENSO) sobre a produtividade, apresentada adiante.

A sazonalidade anual foi representada pela decomposição harmônica do ciclo anual em duas componentes trigonométricas ortogonais, definidas por:

$$saz_{\sin} = \sin\left(\frac{2\pi \cdot \text{mês}}{12}\right), saz_{\cos} = \cos\left(\frac{2\pi \cdot \text{mês}}{12}\right)$$

Essa parametrização permite representar padrões periódicos anuais sem impor relações lineares artificiais entre os meses do ano, além de evitar descontinuidades entre dezembro e janeiro. As duas componentes entram no modelo como preditores distintos, cada um variando entre -1 e $+1$ ao longo do ano, e não como uma soma; ao estimar um coeficiente para cada uma, o modelo ajusta livremente a amplitude e a fase do ciclo anual, pois $\beta_1 \cdot SAZ_{\sin} + \beta_2 \cdot SAZ_{\cos}$ equivale a $A \cdot \sin(2\pi \cdot \text{mês}/12 + \phi)$, com amplitude A e defasagem ϕ determinadas pelos dados. A parametrização não impõe sazonalidade ao modelo: na ausência de ciclo anual nos dados, os coeficientes das duas componentes tendem a zero, tendência reforçada pela penalização L2 da regressão Ridge.

Para verificar empiricamente essa propriedade, o modelo foi reajustado sem as componentes de sazonalidade, mantendo as demais variáveis e o mesmo protocolo de validação (Tabela A3, Apêndice A). A remoção reduziu o R^2 de teste em 21,8 pontos percentuais na Mata Atlântica (de 73,7% para 51,9%), 3,0 pontos no Cerrado e 2,4 pontos na Caatinga, uma queda muito mais acentuada do que se esperaria de um termo redundante, que a penalização L2 tenderia a anular. Essa diferença entre biomas é coerente com o grau em que as próprias variáveis climáticas já estão ligadas ao calendário (Tabela A4, Apêndice A): no Cerrado, entre 70% e 79% da variância da evapotranspiração e do WAI é explicada isoladamente pelo ciclo

anual, contra apenas 40% na Mata Atlântica, onde a variabilidade climática reflete predominantemente as condições meteorológicas de cada ano específico. A acentuada perda de desempenho ao remover a sazonalidade explícita nesse bioma sugere que a Fotossíntese Líquida responde a um componente do ciclo anual, possivelmente fotoperíodo ou fenologia foliar, não inteiramente mediado pelas variáveis climáticas medidas.

Como a área queimada mensal concentra muitos valores nulos e alguns picos muito elevados, aplicou-se, antes da modelagem, a transformação logarítmica a seguir, procedimento usual para reduzir a influência desses valores extremos e melhorar a estabilidade numérica do modelo:

$$BURN_{\log} = \log(1 + x)$$

Para reduzir a influência de meses com produtividade excepcionalmente baixa (por exemplo, após grandes queimadas ou secas severas) sobre a estimação dos coeficientes, a variável resposta foi submetida a winsorização unilateral inferior durante o treinamento. Winsorizar significa substituir os valores abaixo de um limite pelo próprio valor do limite, em vez de excluí-los. O limite adotado foi o percentil 3 da PSN do conjunto de treino, isto é, o valor abaixo do qual estão os 3% menores meses; em uma amostra de cerca de 238 meses de treino, isso afeta apenas os sete valores mais baixos. O percentil foi calculado exclusivamente a partir dos dados de treino de cada partição e aplicado apenas a eles; os valores de PSN dos conjuntos de teste foram mantidos em sua escala original, inclusive os extremos, garantindo que a avaliação preditiva fosse realizada sobre observações não modificadas e evitando vazamento de informação entre treino e teste.

Por fim, todas as variáveis preditoras foram padronizadas por *escore-z* (*StandardScaler*), com média zero e desvio-padrão igual a um. Essa etapa é essencial no contexto da Regressão *Ridge*, pois garante que a penalização L2 atue de forma equilibrada sobre os coeficientes, independentemente da escala original das variáveis. Dessa forma, evita-se que variáveis com magnitudes superiores exerçam influência desproporcional sobre o processo de estimação, contribuindo para maior estabilidade numérica e melhor capacidade de generalização do modelo.

Antes da modelagem, a matriz de correlação de Pearson entre as variáveis candidatas foi examinada para eliminar redundâncias, como no protocolo de Guimarães et al. (2024). A evapotranspiração potencial (ETP) foi excluída nessa etapa por sua correlação de 0,73 a 0,80 com a temperatura da superfície na Mata Atlântica e na Caatinga, permanecendo apenas como

denominador do WAI. As variáveis restantes foram submetidas ao diagnóstico de multicolinearidade por VIF descrito adiante.

5.3 Especificação do Modelo (MRMP-N)

A abordagem de modelagem fundamenta-se na arquitetura do Modelo de Regressão Múltipla Polinomial proposta por Guimarães et al. (2024), originalmente desenvolvida para modelagem quantitativa estrutura-atividade (QSAR) em compostos antimaláricos. No presente trabalho, essa estrutura foi adaptada ao contexto ambiental, substituindo os descritores moleculares pelas variáveis ambientais descritas na Tabela 1, a saber: evapotranspiração (EV), precipitação acumulada (PRE), temperatura da superfície terrestre (TST), índice de disponibilidade hídrica (WAI) e área queimada (BURN), além das duas componentes harmônicas de sazonalidade.

Foram introduzidas três adaptações principais em relação ao modelo de referência: (i) substituição da estimação por Mínimos Quadrados Ordinários (MQO) pela Regressão Ridge com regularização L2, visando reduzir o sobreajuste associado à expansão polinomial; (ii) comparação sistemática dos graus polinomiais 1 a 5, seguindo o mesmo princípio de determinação empírica do grau adotado por Guimarães et al. (2024), que avaliaram graus até 8, com o limite superior reduzido para 5 porque, com cerca de 300 observações e cinco preditores, graus superiores geram centenas de termos e sobreajuste severo; e (iii) ampliação do protocolo de validação, com aplicação de validação cruzada RepeatedKFold, esquemas complementares de validação temporal (GroupKFold por ano e TimeSeriesSplit com janela expansível) e teste de Y-randomization.

A estrutura geral do modelo polinomial pode ser representada por:

$$\hat{Y} = \beta_0 + \sum_i \beta_i X_i + \sum_{i \leq j} \beta_{ij} X_i X_j + \sum_{i \leq j \leq k} \beta_{ijk} X_i X_j X_k + \dots$$

Em que $\hat{Y}$ representa a Fotossíntese Líquida (PSN) estimada; X_i, X_j, X_k correspondem às variáveis preditoras ambientais; β_0 representa o intercepto do modelo; β_i correspondem aos coeficientes dos termos lineares; e β_{ij} e β_{ijk} representam os coeficientes associados aos termos de interação e não lineares, permitindo modelar efeitos combinados entre os preditores ambientais.

Para o grau $N = 2$ e cinco preditores $X_1 \dots X_5$, a expansão gera 20 termos além do intercepto: $\hat{Y} = \beta_0 + \sum_i \beta_i X_i + \sum_i \beta_{ii} X_i^2 + \sum_{i < j} \beta_{ij} X_i X_j$, com 5 termos lineares, 5 quadráticos e 10 interações entre pares. Para um grau N genérico, o número de termos é $C(5 + N, N) - 1$: 20 no

grau 2, 55 no grau 3, 125 no grau 4 e 251 no grau 5, o que ilustra por que graus elevados sobreajustam uma amostra de cerca de 300 meses.

A estimação dos coeficientes do modelo foi realizada por Regressão *Ridge* com regularização L2, cuja função de perda penalizada é definida por:

$$L(\beta) = \sum_{n=1}^N (Y_n - \hat{Y}_n)^2 + \alpha \sum_{p=1}^P \beta_p^2$$

Em que o primeiro termo corresponde à soma dos quadrados dos resíduos e o segundo à penalização L2 aplicada aos coeficientes, controlada pelo parâmetro α . Diferentemente da estimação por Mínimos Quadrados Ordinários (MQO) utilizada por Guimarães et al. (2024), a Regressão Ridge restringe a magnitude dos coeficientes e estabiliza o ajuste na presença de multicolinearidade, aspecto particularmente relevante neste estudo em razão da expansão polinomial, que tende a amplificar correlações existentes entre os preditores originais.

O parâmetro de regularização α foi determinado automaticamente por meio de busca em grade (GridSearchCV). Em cada partição da validação externa, o parâmetro de regularização α foi selecionado por validação cruzada interna de cinco *folds*, constituindo um procedimento aninhado para a otimização desse hiperparâmetro. O conjunto de teste externo permaneceu reservado exclusivamente para a avaliação do desempenho preditivo. A busca foi conduzida sobre o mesmo conjunto de variáveis preditoras do modelo, isto é, EV, PRE, TST, WAI, BURN e as componentes de sazonalidade, com a padronização realizada no âmbito do procedimento de modelagem. Essa abordagem permitiu ajustar o nível de penalização às características dos dados sem utilizar informações do conjunto de teste externo, reduzindo o risco de vazamento de informação e evitando a definição arbitrária de um único valor de regularização.

A ordem polinomial N foi tratada como hiperparâmetro a ser otimizado empiricamente, como no estudo de referência (Guimarães et al., 2024), que também determinou o grau empiricamente. Foram comparados sistematicamente os graus 1 a 5, adotando-se como critério de seleção a maximização do R^2 no conjunto de teste associada à minimização da diferença treino–teste, definida como a diferença entre o R^2 de treino e o R^2 de teste (medida usual do sobreajuste). A avaliação do sobreajuste não se baseou em um limiar rígido único, mas na interpretação conjunta dessa diferença, da estabilidade do R^2 entre as partições e da concordância com a validação temporal. Adotou-se o valor de 10 pontos percentuais como referência orientadora, reconhecendo-se que a magnitude aceitável da diferença depende do mecanismo de controle da capacidade do modelo (no caso, a regularização L2) e da

complexidade intrínseca do fenômeno modelado, não sendo diretamente comparável entre diferentes famílias de modelos. Nesse enquadramento, valores próximos ou moderadamente superiores a esse patamar de referência foram considerados admissíveis quando o modelo manteve desempenho estável e robusto sob validação temporal.

A análise empírica indicou o grau 2 como ótimo para os três biomas analisados, resultado discutido em detalhe no Capítulo de Resultados. Para um conjunto de cinco preditores (três variáveis ambientais selecionadas entre EV, PRE, TST, WAI e BURN, mais as duas componentes de sazonalidade), a expansão polinomial de grau 2 (PolynomialFeatures) gera vinte termos no modelo final, combinando efeitos lineares, quadráticos e de interação entre pares de variáveis, sem impor previamente uma forma funcional rígida às relações ambientais analisadas.

5.4 Análise estatística

A análise estatística do modelo MRMP-N compreendeu três procedimentos integrados: seleção empírica das variáveis preditoras, avaliação do desempenho preditivo e diagnóstico de multicolinearidade. Esses procedimentos foram conduzidos de forma sistemática para cada bioma, garantindo a comparabilidade entre os resultados.

As duas componentes harmônicas de sazonalidade foram mantidas fixas em todos os modelos, por representarem o ciclo anual e não um controle ambiental. A seleção incidiu sobre as cinco variáveis ambientais candidatas (EV, PRE, TST, WAI e BURNlog), avaliando-se todas as $C(5,3) = 10$ combinações de três variáveis por bioma, cada uma sob o mesmo protocolo de validação cruzada. A restrição a três variáveis ambientais (cinco preditores no total) buscou limitar a complexidade dimensional do modelo e favorecer sua estabilidade estatística, aspecto relevante em modelos com expansão polinomial; o controle dos efeitos da multicolinearidade é assegurado pela penalização L2 do Ridge.

Seguindo a lógica de busca combinatória do estudo de referência, que avaliou mais de 400 descritores moleculares em combinações de três, a presente abordagem permite uma avaliação empírica e exaustiva do espaço de combinações possíveis. A seleção final em cada bioma foi definida pelo critério composto que considera, simultaneamente, o maior valor médio de R^2 no conjunto de teste e a menor diferença entre o R^2 de treino e o de teste, evitando-se a escolha de modelos com R^2 de treino elevado mas R^2 de teste baixo, pois é o R^2 no conjunto de teste que mede a capacidade de generalização.

A justificativa empírica para a inclusão das variáveis candidatas baseia-se nas relações univariadas observadas entre a PSN e cada preditor nos três biomas, examinadas previamente por meio de análise gráfica de dispersão. Esse exame orientou a composição do conjunto inicial de candidatas, cujos resultados (Figura 5) são apresentados e discutidos no Capítulo de Resultados.

O desempenho preditivo do modelo foi avaliado por meio de três métricas complementares (R^2 , RMSE e MAE), calculadas sobre o conjunto de teste em cada partição de validação cruzada. Foram reportadas a média e o desvio-padrão das métricas ao longo das partições, permitindo uma estimativa robusta do desempenho e da variabilidade do modelo.

O coeficiente de determinação (R^2) foi utilizado como principal medida do poder explicativo, representando a proporção da variância da PSN explicada pelo modelo. Foram reportados os valores médios para os conjuntos de treino e teste, possibilitando a avaliação simultânea do desempenho preditivo e da diferença treino–teste.

A raiz do erro quadrático médio (RMSE) foi utilizada para quantificar o erro médio de predição na mesma unidade da variável resposta ($\text{gC}\cdot\text{m}^{-2}\cdot\text{mês}^{-1}$), sendo particularmente sensível a erros de maior magnitude. Complementarmente, o erro absoluto médio (MAE) foi empregado como medida mais robusta à presença de outliers, fornecendo uma estimativa direta da magnitude média dos erros de predição.

O diagnóstico de multicolinearidade foi realizado por meio do Fator de Inflação da Variância (VIF), calculado a partir das variáveis preditoras originais, antes da expansão polinomial. Esse procedimento, adotado em conformidade com Guimarães et al. (2024), permite identificar associações lineares entre as variáveis explicativas que possam comprometer a estabilidade dos coeficientes estimados.

Foram considerados como referência os limiares usuais: $\text{VIF} < 5$ (aceitável), $5 \leq \text{VIF} < 10$ (atenção) e $\text{VIF} \geq 10$ (multicolinearidade elevada). Embora a Regressão Ridge ofereça robustez à multicolinearidade por meio da penalização L2, o cálculo do VIF foi mantido como diagnóstico complementar, permitindo identificar variáveis fortemente correlacionadas e interpretar os resultados do modelo com maior cautela.

5.5 Validação do Modelo

A validação do modelo MRMP-N compreendeu a validação cruzada repetida, dois esquemas complementares de validação temporal, a análise de resíduos e o teste de Y-

randomization. Esses procedimentos foram aplicados ao modelo após a definição do conjunto final de variáveis, permitindo uma avaliação complementar de seu comportamento preditivo.


A validação cruzada foi realizada por meio do protocolo *RepeatedKFold*, utilizando cinco *folds* e trinta repetições, resultando em 150 partições de validação para cada combinação avaliada (Figura 4a). Em cada partição, 80% das observações compõem o treino e 20% o teste: com $n = 297$, cerca de 238 meses de treino e 59 de teste. As 30 repetições reembaralham a divisão, de modo que cada mês da série é usado como teste exatamente 30 vezes e como treino 120 vezes ao longo das 150 partições; não há, portanto, um único conjunto de teste fixo, e as métricas reportadas são médias (e desvios-padrão) sobre as 150 partições. Esse protocolo fornece a estimativa principal do desempenho ao reduzir a variabilidade decorrente de partições únicas dos dados. Reconhece-se, contudo, que em séries mensais observações temporalmente próximas podem compartilhar estrutura sazonal e autocorrelação; por isso o desempenho foi adicionalmente examinado por esquemas de validação que respeitam a ordem cronológica, descritos adiante. Adicionalmente, foi reportado o intervalo empírico de 95% da distribuição dos escores de R^2 obtidos nas partições, definido pelos percentis 2,5 e 97,5 dos valores observados. Ressalta-se que, por decorrerem de partições parcialmente sobrepostas do *RepeatedKFold*, esses escores não constituem observações independentes, motivo pelo qual se adota a expressão "intervalo empírico" em vez de "intervalo de confiança" no sentido estatístico estrito.

Para evitar vazamento de informação (*data leakage*), a padronização das variáveis foi ajustada exclusivamente sobre o conjunto de treino de cada partição e posteriormente aplicada ao conjunto de teste sem reestimação dos parâmetros. Esse procedimento impede que informações do conjunto de teste influenciem o processo de treinamento, contribuindo para uma estimativa mais realista da capacidade de generalização do modelo.

Complementarmente à validação cruzada repetida, o desempenho do modelo foi submetido a dois esquemas de validação que respeitam a estrutura cronológica da série, com o objetivo de verificar se as estimativas obtidas pelo *RepeatedKFold* se mantêm quando a separação entre treino e teste preserva a ordem temporal dos dados. O primeiro, denominado *GroupKFold* por ano, agrupa as observações de um mesmo ano em cinco grupos de cinco anos, de modo que anos inteiros sejam mantidos fora do conjunto de treino em cada partição (Figura 4b); esse procedimento avalia a capacidade de generalização do modelo para períodos anuais não utilizados no ajuste e elimina a possibilidade de que meses consecutivos e autocorrelacionados sejam distribuídos simultaneamente entre treino e teste. O segundo, o

TimeSeriesSplit com janela expansível, ajusta o modelo em períodos anteriores e avalia seu desempenho no bloco de 49 meses seguinte, em cinco blocos sucessivos (Figura 4c), simulando o uso preditivo em condições realistas de dependência temporal. Em ambos os esquemas, a winsorização e a padronização foram estimadas exclusivamente sobre o respectivo conjunto de treino, preservando a ausência de vazamento de informação. A concordância entre os resultados dos três esquemas foi interpretada como evidência de que o bom desempenho não decorre apenas de meses vizinhos, muito parecidos entre si, terem caído ao mesmo tempo no treino e no teste.

Figura 4 - Esquemas de particionamento treino/teste: (a) RepeatedKfold 5 × 30; (b) GroupKfold por ano; (c) TimeSeriesSplit com janela expansível.



A análise de resíduos foi conduzida por meio de um ajuste diagnóstico realizado sobre o conjunto completo de dados ($n = 297$, janeiro de 2001 a setembro de 2025), utilizando os valores originais e não winsorizados da PSN. Essa escolha permitiu preservar, na avaliação diagnóstica, os eventos extremos da cauda inferior da distribuição, possibilitando verificar sua influência sobre o comportamento dos resíduos. A normalidade dos resíduos foi avaliada pelo teste de Shapiro-Wilk e a autocorrelação temporal pelo teste de Ljung-Box com 12 defasagens, complementado pela função de autocorrelação (ACF) nas três primeiras defasagens. Ressalta-se que esse ajuste teve finalidade exclusivamente diagnóstica, enquanto a capacidade preditiva do

MRMP-N foi estimada pelos procedimentos de validação cruzada, nos quais a winsorização foi aplicada exclusivamente à resposta do conjunto de treino de cada partição.

O teste de Y-randomization, adaptado de Guimarães et al. (2024), foi aplicado para verificar se o desempenho observado era genuíno e não decorrente de coincidência numérica ou *overfitting*, por meio de validação cruzada (*RepeatedKfold*, 5 partições e 30 repetições), sob o mesmo esquema externo de validação cruzada empregado na avaliação principal, utilizando-se um valor de α previamente definido a partir dos ajustes do modelo original. Em cada permutação, o R^2 de validação cruzada do modelo permutado foi comparado ao R^2 de validação cruzada do modelo original, obtido com α fixado no valor médio dos *folds*. A medição fora da amostra evita que o sobreajuste inerente à expansão polinomial infle o desempenho dos modelos permutados, assegurando que a comparação reflita conteúdo informacional genuíno e não coincidência numérica.

Adotaram-se dois critérios complementares de validação. O primeiro, seguindo a lógica de Guimarães et al. (2024), compara o R^2 de validação cruzada do modelo original com a média dos R^2 dos 100 modelos permutados; neste estudo exigiu-se diferença mínima de 60 pontos percentuais entre os dois. O segundo consiste em um p-valor empírico unilateral, definido como a proporção de permutações cujo R^2 iguala ou supera o do modelo original, adotando-se como significativo p inferior a 0,05.

5.6 Ferramentas Computacionais e Reprodutibilidade

A implementação do modelo foi realizada integralmente em linguagem Python, no ambiente de desenvolvimento Visual Studio Code. A escolha do Python deve-se à sua ampla adoção em modelagem estatística e ambiental, bem como à disponibilidade de bibliotecas consolidadas para análise de dados e aprendizado de máquina.

As principais bibliotecas empregadas foram *pandas* e *numpy* para manipulação e processamento dos dados; *scikit-learn* para padronização (*StandardScaler*), expansão polinomial (*PolynomialFeatures*), Regressão *Ridge*, seleção de hiperparâmetros (*GridSearchCV*) e validação cruzada (*RepeatedKfold*). Foram ainda utilizadas as bibliotecas *scipy.stats* para os testes estatísticos de Shapiro-Wilk e Kruskal-Wallis; *statsmodels* para o ajuste dos modelos de regressão linear por Mínimos Quadrados Ordinários e para o cálculo do Fator de Inflação da Variância (VIF); e *matplotlib* para a geração dos gráficos de diagnóstico e visualização dos resultados.


A reprodutibilidade dos resultados foi assegurada pela fixação de semente aleatória (`random_state = 42`) nos procedimentos que envolvem aleatoriedade, bem como pela organização sistemática dos resultados e pela disponibilização do código-fonte comentado, permitindo transparência e replicabilidade das etapas de modelagem. O valor da semente é arbitrário (42 é uma convenção difundida na comunidade Python); qualquer valor fixo garante que as partições e permutações sejam reproduzidas exatamente, e o resultado não depende do valor escolhido.

6 RESULTADOS E DISCUSSÃO

6.1 Desempenho preditivo do modelo por bioma

Antes da modelagem, as relações univariadas entre a PSN e cada variável candidata foram examinadas por regressão linear simples (Figura 5). No Cerrado e na Caatinga, a evapotranspiração (74,8% e 76,2% da variância da PSN, respectivamente) e o WAI (74,1% e 81,5%) são os preditores univariados mais fortes, seguidos da temperatura, com relação negativa (59,2% e 54,2%); a precipitação do próprio mês explica menos de 10% e a área queimada (em escala logarítmica) associa-se negativamente à PSN nos três biomas. Na Mata Atlântica, nenhuma variável isolada explica mais de 12,5% da variância, o que antecipa o menor desempenho do modelo nesse bioma e a necessidade dos termos de interação.

Figura 5 - Regressão linear simples entre a PSN e cada variável ambiental nos três biomas (dados mensais, n = 297, 2001–2025).



Os resultados obtidos demonstram que o MRMP-N de grau 2, estimado por Regressão Ridge, apresenta desempenho robusto e estatisticamente validado nos três biomas analisados, com capacidade preditiva consistente ao longo das 150 partições de validação cruzada, conforme apresentado na Tabela 2. A diferença entre o R^2 de treino e o de teste permaneceu

bastante reduzida no Cerrado (0,59 pp) e na Caatinga (1,03 pp), e situou-se em 5,19 pp na Mata Atlântica, abaixo do patamar de referência de 10 pontos percentuais. A Figura 6 ilustra a correspondência entre os valores de PSN de referência (estimados pelo produto MODIS MOD17A2H, aqui chamados de observados) e os preditos pelo MRMP-N nos três biomas. Os pontos representam predições fora da amostra (*out-of-fold*) obtidas por validação cruzada de cinco partições, isto é, cada observação foi prevista por um modelo que não a utilizou no treinamento. O R^2 indicado na figura foi calculado diretamente sobre essas predições, enquanto a Tabela 2 apresenta o desempenho médio obtido nas 150 partições do RepeatedKFold.

Figura 6 - Observado vs. predito do MRMP-N nos três biomas.




Tabela 2 - Desempenho preditivo do MRMP-N nos biomas Mata Atlântica, Cerrado e Caatinga na Bahia

Bioma	R^2 teste %	Int. emp. 95%	RMSE	MAE	Dif. treino-teste (pp)
Mata Atlântica	73,7	60,1 – 83,4%	7,97	$6,29 \pm 0,56$	5,19
Cerrado	96,7	95,4 – 97,7%	6,74	$5,43 \pm 0,44$	0,59
Caatinga	94,2	90,8 – 96,2%	6,69	$5,08 \pm 0,49$	1,03

Observa-se elevada capacidade explicativa nos biomas Cerrado e Caatinga, com valores de R^2 superiores a 90%, enquanto a Mata Atlântica apresenta desempenho inferior ($R^2 = 73,7\%$). Essa diferença pode estar associada à maior complexidade e heterogeneidade estrutural da Mata Atlântica, ou seja, ao mosaico de fragmentos florestais, pastagens, plantios de eucalipto e áreas urbanas que compõe o bioma no estado, cuja dinâmica responde a fatores adicionais não

integralmente representados pelos preditores utilizados: biomas cuja produtividade é fortemente controlada por variáveis climáticas tendem a ser mais previsíveis estatisticamente, ao passo que ecossistemas estruturalmente mais heterogêneos respondem a fatores adicionais não capturados por preditores climáticos. Embora os três biomas estejam submetidos a pressões antrópicas, é na Mata Atlântica que a heterogeneidade estrutural resultante dessas pressões mais compromete a previsibilidade da produtividade, conforme detalhado adiante.

O elevado desempenho preditivo no Cerrado ($R^2 = 96,7\%$) reflete a forte sazonalidade hídrica característica desse bioma, no qual a alternância entre estações seca e chuvosa impõe um ritmo regular à atividade fotossintética. Estudos com torres de fluxo no Cerrado demonstram que a produtividade primária varia de forma marcante entre as estações e se correlaciona positivamente com o conteúdo de água no solo e com a precipitação (Arruda et al., 2016; Biudes et al., 2021). A Fotossíntese Líquida apresenta, assim, forte associação com a disponibilidade hídrica, tornando o sinal climático dominante em relação a outros controles ecológicos.

Na Caatinga ($R^2 = 94,2\%$), o elevado desempenho do modelo está associado a um padrão ecológico distinto: o sistema de pulsos de produtividade característico de ambientes semiáridos. Nesse regime, a vegetação responde rapidamente a eventos de precipitação, com aumentos abruptos da PSN após as chuvas e declínios igualmente rápidos durante os períodos secos (Silva et al., 2026). A previsibilidade estatística do modelo decorre justamente dessa resposta direta e quase imediata ao estímulo climático, com forte associação às variações climáticas consideradas no modelo.

Tabela 3 – Comparação do desempenho preditivo (R^2) dos modelos sob diferentes estratégias de validação.

Bioma	<i>RepeatedKFold</i>	<i>GroupKFold</i>	<i>TimeSeriesSplit</i>	Queda máxima
Mata Atlântica	73,65%	73,73%	66,98%	6,66
Cerrado	96,66%	96,38%	95,73%	0,93
Caatinga	94,16%	93,81%	91,20%	2,97

Os resultados das estratégias adicionais de validação (Tabela 3) evidenciaram elevada estabilidade preditiva para os modelos do Cerrado e da Caatinga, que mantiveram valores de R^2 superiores a 90% mesmo em esquemas que consideram explicitamente a estrutura temporal dos dados. Para a Mata Atlântica, o desempenho permaneceu próximo ao do modelo principal na

validação agrupada por ano (73,73%), mas apresentou redução no TimeSeriesSplit (66,98%), indicando maior sensibilidade à ordem temporal e menor capacidade de extrapolação para períodos futuros; ainda assim, a queda ficou abaixo de 10 pontos percentuais nos três biomas.

Já o desempenho inferior da Mata Atlântica ($R^2 = 73,7\%$) reflete a complexidade ecológica e a intensa pressão antrópica que caracterizam esse bioma na Bahia. Parte dessa complexidade é também climática: segundo a classificação de Köppen para o Brasil (Alvares et al., 2013), a faixa atlântica baiana abrange mais de um tipo climático, o que adiciona variabilidade às condições ambientais sob as quais a vegetação responde. A essa diversidade climática soma-se o fato de ser o ecossistema mais fragmentado do estado, no qual o histórico de desmatamento, a expansão da silvicultura de eucalipto e a fragmentação da paisagem introduzem fontes de variabilidade na PSN que não são capturáveis por preditores climáticos isolados (Lima et al., 2020).

Essa heterogeneidade estrutural manifesta-se na coexistência de remanescentes florestais intercalados por pastagens, áreas agrícolas e zonas urbanas, gerando respostas ecossistêmicas locais que superam a capacidade explicativa de variáveis climáticas regionais. Nesse contexto, fatores estruturais como a conectividade entre fragmentos, a idade da regeneração florestal e o histórico de uso do solo emergem como reguladores adicionais da produtividade, atuando por mecanismos como o efeito de borda e a perda de biomassa (Broggio et al., 2024). A incorporação dessas variáveis em estudos futuros pode aumentar significativamente o poder preditivo do modelo nesse bioma.


Em conjunto, os três biomas ilustram um gradiente de previsibilidade climática da PSN: do controle hídrico estrutural no Cerrado, passando pela resposta pulsada da Caatinga, até a complexidade multifatorial da Mata Atlântica. Essa diferenciação reforça que o desempenho do modelo deve ser interpretado não apenas como medida estatística, mas como expressão quantitativa do grau em que cada ecossistema é governado por forçantes climáticas.

6.2 Seleção do grau polinomial e variáveis preditoras

A comparação sistemática entre os graus polinomiais 1 a 5 (Figura 7) indicou o grau 2 como ótimo nos três biomas pelo critério composto de maior R^2 de teste e menor diferença treino–teste. O ganho do grau 2 em relação ao modelo linear (grau 1) foi de 8,4 pontos percentuais de R^2 de teste na Mata Atlântica (65,2% para 73,6%) e de 6,6 pontos no Cerrado (90,1% para 96,7%), mas de apenas 1,3 ponto na Caatinga (92,9% para 94,2%), o que indica resposta quase linear da vegetação semiárida às variáveis hídricas; o grau 2 foi adotado como

grau comum aos três biomas para permitir a comparação entre eles. Na Mata Atlântica, o grau 3 alcançou R^2 de teste 0,8 ponto superior ao do grau 2 (74,4% contra 73,6%), mas com diferença treino–teste 1,7 pontos maior (6,9 contra 5,2 pp) e quase o triplo de termos, sendo preterido pelo critério composto. Graus superiores apresentaram redução progressiva do R^2 de teste e aumento acentuado do sobreajuste (diferenças treino–teste de dezenas a centenas de pontos percentuais nos graus 4 e 5), indicando que a complexidade adicional não se traduz em ganho preditivo real.

Figura 7 - Seleção do grau polinomial do MRMP-N nos três biomas: R^2 de treino e teste e diferença treino–teste por grau.




A escolha do grau 2 carrega implicação ecológica relevante: indica que as relações entre as variáveis climáticas e a Fotossíntese Líquida nos biomas analisados apresentam complexidade moderada, sendo adequadamente representadas por termos quadráticos e de interação entre pares de variáveis. Polinômios de ordem superior, embora matematicamente possíveis, não capturariam estrutura adicional nos dados o que indica que, no conjunto de dados e na estrutura de modelagem adotada, termos quadráticos e interações de segunda ordem foram suficientes para representar a maior parte da estrutura preditiva capturada pelo modelo.

A busca exaustiva entre as $C(5,3) = 10$ combinações de variáveis ambientais (Tabela A2 do Apêndice) identificou conjuntos ótimos distintos entre os biomas, revelando que os controles ambientais da PSN não são uniformes na região. Para a Caatinga, o conjunto ótimo foi EV + PRE + TST + SAZsin + SAZcos, com R^2 de teste médio de 94,2% (diferença treino–teste de 1,03 pp); para a Mata Atlântica, EV + TST + WAI + SAZsin + SAZcos, com R^2 de 73,7% (5,19 pp), superando em 2,7 pontos a combinação EV + PRE + TST, que havia sido a ótima na série original de 2001 a 2020. Esse resultado é notável porque, isoladamente, o WAI explica menos de 2% da variância da PSN na Mata Atlântica (Figura 5): sua contribuição surge apenas em interação com a evapotranspiração e a temperatura, o que ilustra o papel dos termos de segunda ordem. Os pesos das variáveis diferem entre os biomas (Figura 8): na Mata Atlântica a evapotranspiração lidera (26,9%), seguida da sazonalidade e do WAI (19,0%), enquanto na Caatinga a evapotranspiração é o controle dominante (42,8% da importância relativa).

Para o Cerrado, o conjunto ótimo identificado foi EV + PRE + WAI + SAZsin + SAZcos, com R^2 de teste médio de 96,7% e diferença treino–teste de apenas 0,59 pp, a menor de todas as combinações testadas. A Figura 8 ilustra a importância relativa de cada variável preditora nos três biomas, calculada a partir dos coeficientes padronizados do modelo Ridge. A importância relativa de cada variável foi calculada como a soma dos valores absolutos dos coeficientes padronizados de todos os termos (linear, quadrático e de interação) associados à respectiva variável, normalizada de modo que o total por bioma some 100%.

Figura 8 - Importância relativa das variáveis preditoras no modelo MRMP-N nos três biomas.



O resultado mais relevante dessa etapa é a ausência da Temperatura de Superfície Terrestre (TST) no conjunto ótimo do Cerrado, substituída pelo Índice de Disponibilidade Hídrica (WAI). Esse achado não é trivial: indica que, na presença do WAI no modelo, a TST não agrega poder preditivo independente sobre a PSN do Cerrado, tendo seu efeito já capturado pelo WAI. Ressalta-se, contudo, que a vantagem do conjunto com WAI sobre as combinações que

incluem a TST é pequena (de 0,4 ponto percentual no R^2 de teste), ainda que consistente também na menor diferença treino–teste, o que aponta redundância da TST na presença do WAI, e não sua irrelevância ecológica.

Do ponto de vista ecofisiológico, esse resultado é coerente. No Cerrado, a temperatura atua primariamente por meio de seus efeitos sobre o balanço hídrico, elevando a demanda evaporativa e influenciando a disponibilidade de água no solo, processo determinante para a fisiologia e o funcionamento da vegetação savânica (Bucci et al., 2008; Arruda et al., 2016). Assim, o WAI já captura de forma integrada os efeitos combinados da temperatura e da precipitação, tornando a TST redundante como preditor direto. Esse padrão é consistente com a literatura sobre ecossistemas savânicos tropicais, que aponta a limitação hídrica sazonal e não a limitação térmica como o principal controlador da produtividade primária.

A presença das componentes harmônicas de sazonalidade em todos os modelos (mantidas fixas por construção) e o peso que elas recebem nos três biomas reforçam que a PSN na Bahia possui padrão sazonal marcado e regular, associado ao ciclo anual de precipitação e radiação. A evapotranspiração (EV) aparece como preditor central em todos os biomas, e as variáveis hídricas (PRE ou WAI) integram o conjunto ótimo de cada um, confirmando que o balanço hídrico é o controlador primário da produtividade ecossistêmica na região.

Já a ausência da área queimada (BURNlog) no conjunto ótimo de qualquer bioma, apesar de sua inclusão como candidato, sugere que o sinal das queimadas é absorvido pelas variáveis climáticas no poder preditivo do modelo. Isso não implica que as queimadas sejam ecologicamente irrelevantes; pelo contrário, evidências regionais demonstram seu impacto sobre a vegetação e sobre a produtividade primária na Bahia (Benfica et al., 2022). O que esse resultado indica é que a influência das queimadas sobre a PSN se manifesta de forma indireta, principalmente por meio de alterações nas condições hídricas e na cobertura vegetal já capturadas pelos demais preditores. Essa interpretação está alinhada à literatura que descreve o fogo em savanas tropicais como uma perturbação cujo efeito sobre a produtividade é mediado por mudanças na estrutura da vegetação e na dinâmica do carbono entre os compartimentos do sistema solo-vegetação-atmosfera (Navarro-Rosales et al., 2025).

6.3 Papel da disponibilidade hídrica no Cerrado e os regimes de produtividade primária dos biomas da Bahia

A centralidade do WAI como principal preditor do balanço hídrico no Cerrado, em substituição à Temperatura de Superfície Terrestre (TST), configura um resultado relevante para

a compreensão dos controles ecofisiológicos da produtividade em ecossistemas savânicos. O Cerrado é caracterizado por uma sazonalidade hídrica severa, com estação seca prolongada de quatro a seis meses, durante a qual a atividade fotossintética é fortemente reduzida pela limitação da disponibilidade de água no solo. Estudos com torres de fluxo no bioma mostram que a produtividade primária varia de forma marcante entre as estações úmida e seca, acompanhando o conteúdo de água no solo e a precipitação (Arruda et al., 2016; Biudes et al., 2021).

Nesse contexto, o WAI atua como integrador eficiente dos múltiplos controles climáticos sobre a PSN. Conforme definido na seção Dados e Pré-processamento (razão ETR/ETP), o índice expressa em uma única variável o grau em que a demanda atmosférica por água é efetivamente atendida pela água disponível no sistema, refletindo de forma integrada as condições hídricas que limitam a atividade fotossintética. Esse comportamento é consistente com a literatura sobre ecossistemas savânicos tropicais, que aponta a limitação hídrica sazonal, e não a limitação térmica, como o principal controlador da produtividade primária (Vourlitis et al., 2022).

Do ponto de vista das mudanças climáticas, esse resultado carrega implicações preocupantes. As projeções do IPCC (2022) para o Brasil Central e para o bioma Cerrado indicam tendência de intensificação das secas, redução da precipitação anual e aumento da demanda evapotranspirativa decorrente do aquecimento. Como a produtividade do bioma responde de maneira não linear à disponibilidade hídrica, podendo declinar acentuadamente abaixo de determinados limiares de precipitação (Mwangi et al., 2025), reduções sistemáticas do WAI esperadas sob cenários de aquecimento global implicam diretamente em queda da produtividade primária do Cerrado na Bahia.

As consequências desse cenário não se restringem à dimensão biofísica. O Cerrado da Bahia abriga nascentes que abastecem bacias hidrográficas regionais, sustentando atividades agropecuárias, comunidades rurais e ecossistemas a jusante. A perda de produtividade primária associada à redução do WAI pode comprometer simultaneamente os serviços ecossistêmicos de regulação hídrica, a biodiversidade associada à vegetação savânica e a capacidade do bioma de atuar como sumidouro de carbono.

Em síntese, a identificação do WAI como controlador primário da PSN no Cerrado fornece um indicador quantitativo de vulnerabilidade climática para o bioma na região. Esse achado abre caminho para o uso operacional do índice no monitoramento de tendências de

produtividade e na avaliação de impactos climáticos futuros, oferecendo subsídio técnico para estratégias de adaptação e conservação adaptadas à realidade local.

A análise comparativa dos resultados obtidos nas seções anteriores revela que os três biomas da Bahia operam sob regimes ecológicos distintos de controle da produtividade primária, apesar de compartilharem o mesmo território estadual. Essa diferenciação configura uma tipologia ecológica regional, sintetizada na Tabela 4.

Tabela 4 - Tipologia ecológica dos regimes de produtividade primária na Bahia

Bioma	Regime ecológico	Controlador dominante	Previsibilidade da PSN
Cerrado	Limitação hídrica sazonal	Balanço hídrico (EV + WAI)	Alta ($R^2 = 96,7\%$)
Caatinga	Resposta pulsada a eventos de chuva	Evapotranspiração	Alta ($R^2 = 94,2\%$)
Mata Atlântica	Complexidade estrutural multifatorial	Evapotranspiração + sazonalidade + WAI (variabilidade residual antrópica)	Moderada ($R^2 = 73,7\%$)

A tipologia ecológica apresentada na Tabela 4, que sintetiza os regimes de controle da produtividade primária identificados em cada bioma, é coerente com os padrões descritos na literatura para esses ecossistemas: o controle pela limitação hídrica sazonal em savanas tropicais (Vourlitis et al., 2022), a resposta pulsada à precipitação característica de ambientes semiáridos (Silva et al., 2026) e a regulação multifatorial associada à fragmentação e à pressão antrópica na Mata Atlântica (Lima et al., 2020).

Essa tipologia tem implicações metodológicas diretas para o monitoramento ambiental e a modelagem ecológica na região. Em biomas climaticamente limitados, isto é, aqueles em que

a produtividade é controlada principalmente pela água ou pela temperatura, como o Cerrado e a Caatinga, um conjunto reduzido de variáveis climáticas, sobretudo a evapotranspiração, a precipitação, o balanço hídrico (WAI) e as componentes de sazonalidade, é suficiente para capturar grande parte da dinâmica da PSN, viabilizando o uso de modelos preditivos baseados exclusivamente em dados de sensoriamento remoto. Já na Mata Atlântica, a modelagem precisa ser complementada por variáveis estruturais, como índices de fragmentação, conectividade de remanescentes florestais e histórico de uso do solo, para capturar a fração da variabilidade ecológica que escapa aos preditores climáticos.

Mais amplamente, esses três regimes ilustram um princípio ecológico relevante: a previsibilidade estatística de um ecossistema é diretamente proporcional ao grau em que ele é governado por uma única forçante ambiental dominante. Quanto mais multifatorial o controle ecológico, menos previsível o sistema, e maior a necessidade de abordagens analíticas integradas. Essa observação reforça que estratégias homogêneas de gestão e monitoramento tendem a ser ineficazes em paisagens biodiversas como a da Bahia, sendo necessária a adoção de protocolos diferenciados por bioma.


6.4 Diagnóstico estatístico do modelo

A análise de resíduos (Figura 9) indicou distribuição normal na Mata Atlântica (Shapiro-Wilk: $W = 0,996$; $p = 0,630$) e no Cerrado (Shapiro-Wilk: $W = 0,995$; $p = 0,423$), atendendo ao pressuposto de normalidade. Na Caatinga ($W = 0,983$; $p = 0,002$), observou-se desvio de normalidade concentrado na cauda esquerda da distribuição, isto é, alguns meses com produtividade bem abaixo do previsto, coerente com secas severas ou queimadas de grande escala não plenamente capturadas pelos preditores climáticos médios. Adicionalmente, o teste de Ljung-Box detectou autocorrelação residual significativa nos três biomas (Mata Atlântica: $p < 0,001$, ACF de defasagem 1 = 0,51; Cerrado: $p = 0,005$, ACF = 0,20; Caatinga: $p < 0,001$, ACF = 0,42), resultado novo em relação à série de 2001 a 2020, na qual apenas a Caatinga apresentava esse padrão. Essa autocorrelação indica memória temporal não modelada, ou seja, a produtividade de um mês depende em parte das condições dos meses anteriores (por exemplo, da água acumulada no solo), efeito que preditores do mesmo mês não capturam; ela é mais forte na Mata Atlântica, coerente com a resposta defasada da vegetação à disponibilidade hídrica acumulada. Contudo, como o modelo manteve R^2 de 91,20% na Caatinga, 95,73% no Cerrado e 66,98% na Mata Atlântica sob validação TimeSeriesSplit, essa dependência temporal residual

não impediu que a capacidade preditiva permanecesse elevada quando a ordem temporal foi respeitada.

Embora indique um desvio dos pressupostos clássicos, esse comportamento residual deve ser interpretado em conjunto com o desempenho preditivo do modelo, que se manteve estável sob validação cruzada repetida (150 partições) e sob validação temporal. A incorporação explícita da dependência temporal (por exemplo, com preditores defasados ou termos autorregressivos) é uma extensão natural para trabalhos futuros. O diagnóstico completo dos resíduos está apresentado na Figura 9.

Figura 9 - Diagnóstico de resíduos do MRMP-N nos três biomas.




O teste de Y-randomization responde a uma pergunta simples: o modelo encontraria um ajuste parecido se a PSN fosse embaralhada ao acaso? Para isso, a coluna da PSN foi permutada

100 vezes e, a cada vez, o modelo foi reajustado e avaliado por validação cruzada. Os modelos com dados embaralhados tiveram R^2 médio negativo (-10,6% na Mata Atlântica, -10,9% no Cerrado e -13,0% na Caatinga), ou seja, previram pior do que a simples média, enquanto os modelos reais alcançaram 73,8%, 96,7% e 94,2%. A diferença ($\Delta = 84,42$, 107,54 e 107,20 pontos percentuais, respectivamente) supera com folga o mínimo de 60 adotado, e nenhuma das 100 permutações igualou o modelo real (p empírico = 0,0099 nos três biomas). Conclui-se que o desempenho reflete relação genuína entre clima e PSN, e não coincidência numérica ou sobreajuste (Figura 10).

A menor margem de separação da Mata Atlântica é consistente com a elevada variabilidade ecológica intrínseca desse bioma, marcada pela intensa fragmentação da paisagem e pela forte pressão antrópica na Bahia, que introduzem componentes adicionais de variabilidade na PSN não integralmente representados pelos preditores climáticos utilizados no modelo. Os resultados do Y-randomization estão apresentados na Figura 10.

Figura 10 - Y-randomization do MRMP-N nos três biomas.



Em conjunto, os procedimentos de diagnóstico convergem para uma mesma conclusão: o modelo MRMP-N captura estrutura ecológica genuína nos três biomas, apresentando desempenho estatisticamente robusto e coerente com as características ambientais de cada ecossistema. O diagnóstico de multicolinearidade (Tabela 5) mostra colinearidade elevada apenas onde a evapotranspiração e o WAI integram juntos o modelo no Cerrado (Cerrado: VIF de 36,99 (EV) e 31,61 (WAI)), controlada pela penalização L2 do Ridge mas que exige cautela na interpretação isolada dos coeficientes dessas duas variáveis; na Mata Atlântica e na Caatinga todos os VIF ficaram abaixo de 5,1. Essas particularidades, junto com a não normalidade dos resíduos da Caatinga, a autocorrelação residual nos três biomas e a menor margem de Y-randomization na Mata Atlântica, não comprometem a validade do modelo, refletindo características ecológicas legítimas dos sistemas analisados.

Tabela 5 - Fator de Inflação da Variância (VIF) das variáveis preditoras por bioma.

Variável	Mata Atlântica	Cerrado	Caatinga
EV	2,65	36,99	5,02
PRE	—	4,02	1,68
TST	4,23	—	3,90
WAI	3,54	31,61	—
SAZsin	1,65	4,49	2,63
SAZcos	3,92	3,59	3,76


6.5 Influência do ENSO sobre a produtividade dos biomas

A fase ENSO de cada mês foi classificada pelo critério oficial da NOAA (ONI igual ou superior a $+0,5$ °C, ou igual ou inferior a $-0,5$ °C, por pelo menos cinco trimestres móveis consecutivos), o que resultou em 149 meses neutros, 76 de El Niño e 72 de La Niña, sem defasagem entre a fase e as variáveis do mês. O teste de Kruskal-Wallis não detectou diferenças estatisticamente significativas da PSN entre as fases na Mata Atlântica ($p = 0,065$) nem no Cerrado ($p = 0,093$), mas as detectou na Caatinga ($p = 0,010$), onde a PSN média cai de $94,2 \text{ gC} \cdot \text{m}^{-2} \cdot \text{mês}^{-1}$ nos meses de La Niña para $87,0$ nos neutros e $79,7$ nos de El Niño. Esse é um resultado novo em relação à série de 2001 a 2020, na qual nenhum bioma apresentava diferença direta. Nos outros dois biomas, o resultado torna-se mais claro quando analisado à luz do comportamento das variáveis climáticas intermediárias: a influência do ENSO sobre a produtividade primária não ocorre de forma direta, mas mediada pelas respostas das variáveis ambientais regionais.

Na Mata Atlântica, a Temperatura de Superfície Terrestre (TST) foi a variável climática mais sensível às fases do ENSO ($p < 0,001$), com médias de $28,8$ °C em La Niña, $27,1$ °C em meses neutros e $29,7$ °C em El Niño (Figura 11). A evapotranspiração também diferiu entre fases ($p = 0,006$), enquanto a precipitação não ($p = 0,349$), sugerindo que o efeito climático do ENSO sobre esse bioma se manifesta predominantemente pela componente térmica. Esse predomínio é coerente com a elevada umidade regional da Mata Atlântica, onde variações de temperatura tendem a exercer influência mais perceptível sobre os processos ecofisiológicos do que pequenas oscilações hidrológicas. Vale distinguir, contudo, que a sensibilidade da TST às fases do ENSO e a importância da TST como preditora da PSN são propriedades distintas: a primeira descreve como o fenômeno climático modula a temperatura, enquanto a segunda, apresentada na análise de importância das variáveis (Figura 8), reflete o peso da temperatura no


controle direto da produtividade. Assim, a TST atua como elo entre a variabilidade climática de larga escala associada ao ENSO e a resposta produtiva local da vegetação.

Figura 11 - Distribuição das variáveis ambientais por fase ENSO na Mata Atlântica.




No Cerrado, a temperatura ($p = 0,003$), a precipitação ($p < 0,001$) e a evapotranspiração ($p < 0,001$) diferiram entre as fases do ENSO (Figura 12). A precipitação média mensal foi de 123,3 mm em La Niña, 59,0 mm em meses neutros e 106,6 mm em El Niño, com a evapotranspiração acompanhando o mesmo padrão. Esse resultado é consistente com a posição geográfica do bioma e com a literatura que documenta a influência do ENSO sobre o regime pluviométrico do Brasil Central. Como a dinâmica ecológica do Cerrado é fortemente condicionada pela sazonalidade hídrica, alterações nas chuvas associadas às fases do ENSO repercutem sobre a disponibilidade hídrica e, potencialmente, sobre a produtividade vegetal, ainda que, na escala mensal e no período analisado, a diferença direta da PSN entre fases não tenha atingido significância ($p = 0,093$).

Figura 12 - Distribuição das variáveis ambientais por fase ENSO no Cerrado.



Na Caatinga, as três variáveis climáticas responderam às fases do ENSO (TST: $p < 0,001$; PRE: $p < 0,001$; EV: $p = 0,002$), com precipitação média de 73,4 mm em La Niña contra 45,9 mm em meses neutros e 65,7 mm em El Niño (Figura 13). Diferentemente dos outros biomas, aqui a resposta chegou à própria PSN: a produtividade média dos meses de El Niño foi cerca de 15% inferior à dos meses de La Niña. Esse comportamento é coerente com o regime pulsado do bioma semiárido, no qual a produtividade responde de forma quase imediata à disponibilidade de água, e com os achados de Silva et al. (2026), que associam anos de El Niño a reduções da produtividade na Caatinga.

Figura 13 - Distribuição das variáveis ambientais por fase ENSO na Caatinga.



Em contrapartida, quando a intensidade do ONI é usada como preditor contínuo, o poder explicativo é baixo: a regressão linear simples do ONI sobre cada variável climática explicou no máximo 3,0% de sua variância (temperatura da Mata Atlântica), e menos de 2% em todos os demais casos. A correlação de Pearson entre o ONI e a PSN foi negativa e significativa na Mata Atlântica ($r = -0,240$; $p < 0,001$) e na Caatinga ($r = -0,155$; $p = 0,007$), e não significativa no Cerrado ($r = -0,071$). Esses resultados evidenciam que a influência do ENSO sobre o sistema ambiental regional não se manifesta de forma linear direta, mas por meio de relações indiretas e não lineares, mais adequadamente representadas pela classificação categórica em fases.

A interpretação conjunta desses resultados sustenta um padrão compatível com uma influência predominantemente indireta, na qual o ENSO atua como forçante climática de larga escala que modula variáveis intermediárias (temperatura nos três biomas; precipitação e evapotranspiração no Cerrado e na Caatinga), com efeito direto sobre a PSN detectável apenas no bioma mais sensível à água, a Caatinga.

A ausência de efeito direto do ENSO sobre a PSN na Mata Atlântica e no Cerrado, apesar da resposta significativa das variáveis climáticas, sugere que esses ecossistemas apresentam

capacidade parcial de amortecimento frente às oscilações climáticas de larga escala. Essa capacidade decorre, em parte, da própria sazonalidade interna dos biomas, que estrutura a produtividade primária em torno de ciclos anuais relativamente regulares, cuja amplitude pode superar as perturbações induzidas pelo ENSO em escala mensal. Na Caatinga, onde a reserva hídrica do sistema é menor, esse amortecimento é insuficiente.

Esse resultado, contudo, não deve ser interpretado como ausência de vulnerabilidade climática. Sob cenários de intensificação dos eventos ENSO particularmente episódios de El Niño mais frequentes e severos, projetados para o século XXI a magnitude das alterações em temperatura e precipitação pode ultrapassar a capacidade de amortecimento dos ecossistemas, resultando em impactos mais pronunciados sobre a PSN. Nesse contexto, a utilização de variáveis climáticas proximais, como evapotranspiração (EV), precipitação (PRE) e temperatura (TST), mostrou-se metodologicamente adequada para capturar os efeitos indiretos do ENSO sobre a produtividade primária sem a necessidade de inclusão explícita do ONI no modelo principal.

6.6 Implicações ambientais e para o planejamento regional

Os resultados deste estudo transcendem o âmbito estatístico e oferecem subsídios técnicos concretos para o planejamento ambiental da Bahia. Trata-se de uma região que concentra três biomas de elevada relevância ecológica e abriga povos indígenas de diversas etnias (Pataxó, Pataxó Hã-Hã-Hãe, Tupinambá, Kiriri, Tuxá, Pankararé, Truká e Kaimbé, entre outras), comunidades quilombolas e agricultores familiares que dependem diretamente dos serviços ecossistêmicos associados à dinâmica da produtividade vegetal e à assimilação de carbono notadamente o sequestro de carbono e a regulação climática, a regulação hídrica, a ciclagem de nutrientes e a manutenção da fertilidade do solo, além do provisionamento de alimentos, fibras e recursos florestais (madeireiros e não madeireiros). A tipologia ecológica identificada na Tabela 4 aponta para a necessidade de estratégias diferenciadas de gestão, conservação e monitoramento por bioma, como detalhado a seguir.

Para a Mata Atlântica, o menor poder preditivo do modelo climático ($R^2 = 73,7\%$) é compatível com a hipótese de que fatores de paisagem, como a expansão da monocultura de eucalipto e a fragmentação, expliquem parte da variância não capturada pelo clima; testar essa hipótese exigiria incluir variáveis de uso do solo no modelo, o que se recomenda para trabalhos futuros. Se confirmada, ela indica que políticas de restauração florestal e controle do desmatamento têm potencial direto de reduzir a variabilidade da PSN e elevar a produtividade

ecossistêmica, ampliando os serviços de sequestro de carbono e regulação hídrica prestados pelo bioma.

A Mata Atlântica da Bahia integra o Corredor Central da Mata Atlântica, um dos eixos prioritários da conservação no país. Os resultados aqui obtidos reforçam a urgência de estratégias de conectividade entre fragmentos florestais como condição para a resiliência ecossistêmica frente às mudanças climáticas projetadas para a região.

Para o Cerrado, a centralidade do WAI como preditor da PSN aponta que a conservação da disponibilidade hídrica por meio da proteção de nascentes, manutenção da cobertura vegetal nativa e controle das queimadas constitui a intervenção de maior impacto para a manutenção da produtividade e dos serviços ecossistêmicos do bioma. Sob cenários de intensificação das secas, a proteção hídrica torna-se uma prioridade estratégica não apenas para a biodiversidade, mas também para a sustentabilidade da agropecuária e dos recursos hídricos regionais.

Para a Caatinga, o alto desempenho preditivo do modelo ($R^2 = 94,2\%$) demonstra que a PSN responde de forma previsível às condições climáticas, abrindo possibilidades concretas para o desenvolvimento de sistemas de alerta precoce de declínio de produtividade baseados em dados de sensoriamento remoto. Tal ferramenta teria aplicação direta no monitoramento da segurança alimentar e hídrica das populações rurais, especialmente em anos de El Niño, quando a redução da precipitação intensifica a limitação hídrica do bioma.

Em conjunto, os resultados deste estudo fornecem uma base técnica quantitativa alinhada aos objetivos do Zoneamento Ecológico-Econômico da Bahia e às metas de restauração florestal do Plano Nacional de Recuperação da Vegetação Nativa (PLANAVEG). Mais amplamente, ao demonstrar que os controles ecológicos da produtividade variam substancialmente entre biomas vizinhos, o estudo evidencia a importância de abordagens regionalizadas para a tomada de decisão ambiental uma orientação que se torna ainda mais crítica em um contexto de mudanças climáticas, no qual a heterogeneidade dos sistemas naturais exige instrumentos de gestão igualmente diferenciados.

7 CONSIDERAÇÕES FINAIS

Esta dissertação investigou a influência de variáveis ambientais sobre a Fotossíntese Líquida (PSN) nos biomas Mata Atlântica, Cerrado e Caatinga, na Bahia, por meio do desenvolvimento e validação de um Modelo de Regressão Múltipla Polinomial de ordem N (MRMP-N). A pesquisa partiu da premissa de que abordagens lineares tradicionais apresentam limitações para representar a complexidade ecológica regional, propondo uma alternativa

baseada em regressão polinomial com regularização Ridge, capaz de acomodar relações não lineares e efeitos de interação entre variáveis ambientais.

Os principais resultados confirmaram a viabilidade do modelo nos três biomas analisados. O MRMP-N de grau 2 apresentou elevado desempenho preditivo no Cerrado ($R^2 = 96,7\%$) e na Caatinga ($R^2 = 94,2\%$), além de desempenho moderado na Mata Atlântica ($R^2 = 73,7\%$), refletindo regimes ecológicos distintos de controle da produtividade primária na região. A extensão da série para 2001–2025 (297 meses) elevou o R^2 da Mata Atlântica em relação à série original de 2001–2020 (de 62,3% para 73,7%) e manteve os do Cerrado e da Caatinga, indicando estabilidade do modelo frente aos anos recentes, que incluíram o El Niño intenso de 2023–2024.

Retomando as hipóteses formuladas: a H1 confirmou-se, com uma ressalva. O grau 2 superou o modelo linear nos três biomas (8,4, 6,6 e 1,3 pontos percentuais de R^2 de teste na Mata Atlântica, no Cerrado e na Caatinga), mantendo a diferença treino–teste abaixo de 10 pontos; na Caatinga, porém, o ganho foi marginal. A H2 confirmou-se: o conjunto de variáveis climáticas associado às componentes de sazonalidade explicou entre 73,7% e 96,7% da variância da PSN, acima do limiar de 60% estabelecido, e a composição do conjunto ótimo diferiu entre os biomas: EV + PRE + TST na Caatinga, EV + PRE + WAI no Cerrado e EV + TST + WAI na Mata Atlântica, confirmando a maior relevância do Índice de Disponibilidade Hídrica (WAI) em sistemas com forte sazonalidade hídrica e, na Mata Atlântica, a importância das interações entre variáveis. Ressalva-se ainda que, pelo critério estrito de H1, o grau 3 atenderia tecnicamente à definição de otimalidade na Mata Atlântica (R^2 de teste de 74,4%, 0,8 ponto acima do grau 2, com diferença treino–teste de 6,9 pp, ainda dentro do limite de 10 pontos). Optou-se, contudo, pelo grau 2 como grau comum aos três biomas, tanto por parcimônia, com 20 termos contra 55, mais que o dobro, para um ganho marginal, quanto por ele ser inequivocamente superior ao grau 3 no Cerrado e na Caatinga, em R^2 de teste e em diferença treino–teste, o que reforça sua adequação como escolha comum de comparação entre os três biomas.

A H3 confirmou-se em sua essência: o ONI explicou no máximo 3% da variância das variáveis climáticas e, embora tenha modulado a temperatura nos três biomas e a precipitação no Cerrado e na Caatinga, só se associou a diferenças diretas da PSN na Caatinga, o bioma mais sensível à disponibilidade de água. O padrão é, portanto, o de uma influência predominantemente indireta, mediada pela temperatura e pela precipitação.

Em relação aos objetivos específicos, todos foram alcançados. O modelo MRMP-N foi desenvolvido e validado por meio de validação cruzada RepeatedKFold, esquemas de validação

temporal (GroupKFold por ano e *TimeSeriesSplit*) e teste de Y-randomization, garantindo robustez estatística e capacidade de generalização. O grau polinomial ótimo foi determinado empiricamente, identificando-se o grau 2 como aquele que melhor equilibra desempenho preditivo e controle de *overfitting*. Adicionalmente, foi identificado um conjunto ótimo de variáveis preditoras para cada bioma, permitindo caracterizar diferenças ecológicas regionais nos mecanismos de controle da produtividade primária.

O desempenho comparativo entre os três biomas evidenciou regimes ecológicos distintos de controle da PSN, revelando um gradiente regional de previsibilidade climática da produtividade primária. No Cerrado e na Caatinga, a produtividade mostrou-se fortemente condicionada pelas variáveis climáticas e pelo balanço hídrico, resultando em elevada previsibilidade estatística. Na Mata Atlântica, por outro lado, a maior heterogeneidade estrutural da paisagem e a intensa pressão antrópica introduziram componentes adicionais de variabilidade não plenamente capturados pelos preditores climáticos utilizados no modelo. Adicionalmente, a investigação do efeito do ENSO confirmou sua atuação como forçante climática indireta, mediada principalmente pelas variáveis de temperatura e precipitação, com efeito direto sobre a PSN detectado apenas na Caatinga.

Algumas limitações do estudo devem ser reconhecidas. A modelagem baseou-se predominantemente em variáveis climáticas, hídricas e sazonais, não incorporando variáveis estruturais da paisagem, como fragmentação florestal, conectividade de remanescentes e histórico de uso do solo, fatores potencialmente relevantes para explicar a variabilidade residual da PSN especialmente na Mata Atlântica. Além disso, a escala temporal mensal utilizada, embora adequada para capturar tendências de médio prazo, apresenta limitações para representar eventos extremos de curta duração. Adicionalmente, a abordagem estatística adotada possui natureza correlacional, não permitindo inferências causais diretas sobre os mecanismos ecofisiológicos envolvidos. Cabe ainda registrar que o MRMP-N é um modelo explicativo-preditivo contemporâneo: ele estima a PSN de um mês a partir das variáveis ambientais desse mesmo mês e, portanto, não gera previsões autônomas do futuro; para projetar a PSN de meses vindouros, seria necessário alimentá-lo com valores observados ou previstos de EV, PRE, TST e WAI. Por fim, a autocorrelação residual detectada nos três biomas indica que parte da memória temporal do sistema não é capturada por preditores do mesmo mês.

Apesar dessas limitações, o estudo apresenta implicações relevantes para a ciência ambiental e para o planejamento regional na Bahia. Do ponto de vista metodológico, demonstra-se que modelos polinomiais com regularização Ridge constituem alternativa viável e

reprodutível para a modelagem de processos ecológicos complexos, conciliando flexibilidade funcional e controle estatístico. Do ponto de vista ecológico, os resultados reforçam que biomas vizinhos podem apresentar mecanismos de controle da produtividade substancialmente distintos, evidenciando a necessidade de estratégias regionalizadas de monitoramento e gestão ambiental.

Do ponto de vista aplicado, os resultados fornecem subsídios quantitativos para instrumentos como o Zoneamento Ecológico-Econômico da Bahia e o Plano Nacional de Recuperação da Vegetação Nativa (PLANAVEG) ao identificar, para cada bioma, os principais controles climáticos e hídricos da produtividade primária e ao apontar prioridades de intervenção. No Cerrado, a centralidade do WAI indica a proteção da disponibilidade hídrica como diretriz de zoneamento; na Mata Atlântica, o menor poder preditivo do clima e a influência da fragmentação apontam a restauração florestal e a conectividade de remanescentes como metas prioritárias; e na Caatinga, a alta previsibilidade climática da PSN viabiliza o monitoramento contínuo da produtividade por sensoriamento remoto. Esses elementos oferecem critérios técnicos objetivos para a definição de prioridades de conservação, restauração e uso do solo, além de apontarem potencial para o desenvolvimento de sistemas de alerta precoce de declínio de produtividade. Tais aplicações possuem relevância direta para a conservação da biodiversidade, a segurança hídrica e o planejamento ambiental de populações que dependem dos serviços ecossistêmicos regionais.

Como perspectivas para trabalhos futuros, sugere-se a incorporação explícita da dependência temporal, por meio de preditores defasados ou termos autorregressivos, para absorver a autocorrelação residual identificada; a análise da influência do ENSO com defasagens de um a seis meses entre o ONI e a resposta da vegetação; a incorporação de variáveis estruturais da paisagem em estudos voltados à Mata Atlântica; a utilização de escalas temporais mais finas para investigação de eventos extremos; e a aplicação do modelo MRMP-N em outras regiões com gradientes ambientais semelhantes, visando avaliar sua capacidade de generalização. Adicionalmente, a integração entre abordagens estatísticas e modelos ecofisiológicos baseados em processos pode contribuir para aprofundar a compreensão dos mecanismos ambientais que regulam a Fotossíntese Líquida (PSN) nos ecossistemas tropicais.

Bioma	Variáveis	R² treino (%)	R² teste (%)	Dif. treino–teste (pp)
Caatinga	EV + TST + BURNlog	93,8	92,5	1,2
Caatinga	TST + WAI + BURNlog	91,6	89,7	1,9
Caatinga	PRE + TST + BURNlog	81,4	77,9	3,4
Cerrado	EV + PRE + WAI	97,3	96,7	0,6
Cerrado	EV + PRE + TST	97,0	96,3	0,7
Cerrado	EV + PRE + BURNlog	96,9	95,8	1,2
Cerrado	EV + TST + WAI	96,0	95,2	0,9
Cerrado	EV + WAI + BURNlog	96,0	94,2	1,8
Cerrado	PRE + TST + WAI	95,1	93,8	1,4
Cerrado	EV + TST + BURNlog	94,8	93,3	1,5
Cerrado	PRE + WAI + BURNlog	95,0	92,6	2,4
Cerrado	TST + WAI + BURNlog	91,3	88,8	2,4
Cerrado	PRE + TST + BURNlog	75,6	71,3	4,3
Mata Atlântica	EV + TST + WAI	78,8	73,6	5,2
Mata Atlântica	EV + PRE + TST	76,1	71,0	5,1
Mata Atlântica	EV + PRE + WAI	74,4	69,0	5,4
Mata Atlântica	EV + WAI + BURNlog	72,8	66,4	6,4
Mata Atlântica	EV + PRE + BURNlog	71,8	66,0	5,8
Mata Atlântica	EV + TST + BURNlog	66,0	58,4	7,6
Mata Atlântica	PRE + TST + WAI	63,7	55,7	8,0
Mata Atlântica	PRE + TST + BURNlog	56,0	47,7	8,3
Mata Atlântica	PRE + WAI + BURNlog	57,2	47,6	9,6
Mata Atlântica	TST + WAI + BURNlog	52,2	41,4	10,8

Tabela A3 - Efeito da remoção das componentes de sazonalidade harmônica no desempenho do MRMP-N (grau 2, RepeatedKFold 5 × 30).

Bioma	Conjunto de variáveis	R² treino (%)	R² teste (%)	Dif. treino–teste (pp)	RMSE
Mata Atlântica	EV+TST+WAI+SAZsin+SAZcos	78,8	73,7	5,2	7,97
Mata Atlântica	EV+TST+WAI (sem sazonalidade)	55,7	51,9	3,8	10,78
Cerrado	EV+PRE+WAI+SAZsin+SAZcos	97,3	96,7	0,6	6,74
Cerrado	EV+PRE+WAI (sem sazonalidade)	94,7	93,7	1,0	9,28
Caatinga	EV+PRE+TST+SAZsin+SAZcos	95,2	94,2	1,0	6,69
Caatinga	EV+PRE+TST (sem sazonalidade)	92,8	91,8	1,1	7,96

Tabela A4 - Proporção da variância de cada variável climática explicada isoladamente pelo ciclo anual (regressão contra SAZsin e SAZcos).

Bioma	Variável	R² (%)
Mata Atlântica	TST	64,9
Mata Atlântica	EV	39,8
Mata Atlântica	WAI	39,8
Cerrado	EV	79,1
Cerrado	WAI	70,2
Cerrado	PRE	58,9
Caatinga	EV	63,3
Caatinga	TST	54,2
Caatinga	PRE	31,5

8 REFERÊNCIAS

- ALVARES, C. A.; STAPE, J. L.; SENTELHAS, P. C.; GONÇALVES, J. L. M.; SPAROVEK, G. Köppen's climate classification map for Brazil. *Meteorologische Zeitschrift*, v. 22, n. 6, p. 711-728, 2013. DOI: 10.1127/0941-2948/2013/0507.
- ARRUDA, P. H. Z. de; VOURLITIS, G. L.; SANTANNA, F. B.; PINTO, O. B.; LOBO, F. A.; NOGUEIRA, J. S. Large net CO₂ loss from a grass-dominated tropical savanna in south-central Brazil in response to seasonal and interannual drought. *Journal of Geophysical Research: Biogeosciences*, v. 121, n. 8, p. 2110-2124, 2016. DOI: 10.1002/2016JG003404.
- BENFICA, N. S. et al. The relation between net primary productivity and human activities for three biomes in Bahia state, Brazil. *Geography, Environment, Sustainability*, v. 15, n. 4, p. 6-16, 2022.
- BIUDES, M. S. et al. Gross primary productivity of Brazilian Savanna (Cerrado) estimated by different remote sensing-based models. *Agricultural and Forest Meteorology*, v. 307, 108456, 2021. DOI: 10.1016/j.agrformet.2021.108456.
- BROGGIO, I. S.; SILVA-JUNIOR, C. H. L.; NASCIMENTO, M. T.; VILLELA, D. M.; ARAGÃO, L. E. O. C. Quantifying landscape fragmentation and forest carbon dynamics over 35 years in the Brazilian Atlantic Forest. *Environmental Research Letters*, v. 19, n. 3, 034047, 2024. DOI: 10.1088/1748-9326/ad281c.
- BUCCI, S. J.; SCHOLZ, F. G.; GOLDSTEIN, G.; MEINZER, F. C.; FRANCO, A. C.; ZHANG, Y.; HAO, G. Y. Water relations and hydraulic architecture in Cerrado trees: adjustments to seasonal changes in water availability and evaporative demand. *Brazilian Journal of Plant Physiology*, v. 20, n. 3, p. 233-245, 2008.
- DIONIZIO, E. A.; PIMENTA, F. M.; LIMA, L. B.; COSTA, M. H. Carbon stocks and dynamics of different land uses on the Cerrado agricultural frontier. *PLoS ONE*, v. 15, n. 11, e0241637, 2020. DOI: 10.1371/journal.pone.0241637.
- FLORES, B. M. et al. Critical transitions in the Amazon forest system. *Nature*, v. 626, p. 555-564, 2024.

GUIMARÃES, R. M. S. et al. Application of machine learning in the development of fourth degree quantitative structure-activity relationship model for triclosan analogs tested against *Plasmodium falciparum* 3D7. *ACS Omega*, v. 9, n. 44, p. 44436-44447, 2024.

HAO, T. et al. A review of evidence about use and performance of species distribution modelling ensembles like BIOMOD. *Diversity and Distributions*, v. 25, n. 5, p. 838-847, 2019.

INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). *Mapa de Biomas do Brasil: primeira aproximação*. Rio de Janeiro: IBGE; MMA, 2004.

INSTITUTO NACIONAL DE PESQUISAS ESPACIAIS (INPE). Centro de Previsão de Tempo e Estudos Climáticos. *Monitoramento do El Niño e La Niña*. São José dos Campos: INPE, 2020. Disponível em: <http://enos.cptec.inpe.br/>. Acesso em: 11 out. 2025.

INTERGOVERNMENTAL PANEL ON CLIMATE CHANGE (IPCC). *Climate Change 2022: Impacts, Adaptation and Vulnerability. Summary for Policymakers*. Geneva: IPCC, 2022.

JIN, Y.; LI, J.; LIU, C. et al. Response of net primary productivity to precipitation exclusion in a savanna ecosystem. *Forest Ecology and Management*, v. 429, p. 69-76, 2018. DOI: 10.1016/j.foreco.2018.07.007.

LEVIN, S. A. Ecosystems and the biosphere as complex adaptive systems. *Ecosystems*, v. 1, n. 5, p. 431-436, 1998.

LIMA, R. A. F. de; OLIVEIRA, A. A.; PITTA, G. R.; GASPER, A. L. de; VIBRANS, A. C.; CHAVE, J.; TER STEEGE, H.; PRADO, P. I. The erosion of biodiversity and biomass in the Atlantic Forest biodiversity hotspot. *Nature Communications*, v. 11, 6347, 2020. DOI: 10.1038/s41467-020-20217-w.

LINGER, E.; HOGAN, J. A.; CAO, M.; ZHANG, W.-F.; YANG, X.-F.; HU, Y.-H. Precipitation influences on the net primary productivity of a tropical seasonal rainforest in Southwest China: a 9-year case study. *Forest Ecology and Management*, v. 467, 118153, 2020. DOI: 10.1016/j.foreco.2020.118153.

MAPBIOMAS. *Coleção 10 da Série Anual de Mapas de Uso e Cobertura da Terra do Brasil (1985-2024)*. MapBiomas, 2025. Disponível em: <https://brasil.mapbiomas.org/>. Acesso em: 22 jun. 2026.

- MWANGI, B. N.; AYOMA, W.; LI, Y. et al. Drought-driven declines in water-use efficiency reshape carbon dynamics of a subtropical forest. *Ecological Processes*, v. 14, 2025. DOI: 10.1186/s13717-025-00629-6.
- NAVARRO-ROSALES, F. et al. The effect of fire on the carbon fluxes and productivity of Brazilian woodland savannas. *Science of The Total Environment*, v. 987, 179626, 2025. DOI: 10.1016/j.scitotenv.2025.179626.
- NEMANI, R. R. et al. Climate-driven increases in global terrestrial net primary production from 1982 to 1999. *Science*, v. 300, n. 5625, p. 1560-1563, 2003.
- NATIONAL OCEANIC AND ATMOSPHERIC ADMINISTRATION (NOAA). *Climate Prediction Center: Oceanic Niño Index (ONI)*. College Park: NOAA, 2025. Disponível em: https://origin.cpc.ncep.noaa.gov/products/analysis_monitoring/ensostuff/ONI_v5.php. Acesso em: 11 out. 2025.
- RIBEIRO, M. C. et al. The Brazilian Atlantic Forest: how much is left, and how is the remaining forest distributed? Implications for conservation. *Biological Conservation*, v. 142, n. 6, p. 1141-1153, 2009.
- RUNNING, S. W. et al. A continuous satellite-derived measure of global terrestrial primary production. *BioScience*, v. 54, n. 6, p. 547-560, 2004.
- RUNNING, S. W.; ZHAO, M. *User's guide: NASA MOD17 daily GPP and annual NPP (MOD17A2H/A3H) and year-end gap-filled products, Collection 6.1*. Missoula: Numerical Terradynamic Simulation Group, University of Montana, 2021.
- SILVA, C. V. J. et al. Climatic stress versus anthropogenic degradation: an ecohydrological perspective on the drivers of net primary productivity in a seasonally dry tropical forest. *Ecohydrology*, v. 19, 2026. DOI: 10.1002/eco.70220.
- VOURLITIS, G. L. et al. Net primary production and ecosystem carbon flux of Brazilian tropical savanna ecosystems from *eddy covariance* and inventory methods. *Journal of Geophysical Research: Biogeosciences*, v. 127, e2021JG006780, 2022.
- ZHAO, M.; HEINSCH, F. A.; NEMANI, R. R.; RUNNING, S. W. Improvements of the MODIS terrestrial gross and net primary production global data set. *Remote Sensing of Environment*, v. 95, n. 2, p. 164-176, 2005.